ÉCOLE NORMALE SUPÉRIEURE PARIS-SACLAY

Université Paris-Saclay

SATIE

Laboratoire des systèmes et applications des technologies de l'information et de l'énergie

Modèles de diffusion appliqués aux problèmes inverses : estimation variationnelle bayésienne des hyperparamètres

Gatien Séguy

Laboratoire : SATIE – ENS Paris-Saclay

Superviseur : Thomas Rodet (SATIE – CNRS)

Date de début : 1er avril 2026

Date de fin : 15 juillet 2026

RÉSUMÉ

Ce stage porte sur la résolution de problèmes inverses en imagerie à l'aide de modèles de diffusion génératifs. Nous formalisons d'abord le processus de diffusion forward comme une équation différentielle stochastique, établissons la formule de Tweedie reliant le score à l'estimateur optimal, et présentons les méthodes existantes de reconstruction conditionnelle (DPS, ΠGDM). Nous proposons ensuite une approche combinant le cadre ΠGDM avec l'inférence variationnelle bayésienne (algorithme EMG-VBA) pour estimer automatiquement les hyperparamètres du modèle (τ_r, τ_b) plutôt que de les fixer manuellement. Contrairement aux méthodes classiques qui décomposent le score conditionnel en score a priori et score de vraisemblance, notre formulation fournit le score conditionnel total en forme fermée. L'optimisation est menée dans l'espace des mesures de probabilité via des mises à jour multiplicatives (Radon-Nikodym).

Stage de recherche – Master 2 M2FESup Intranet

Table des matières

Modèles de Diffusion Génératifs 4

I Introduction 4

II Processus de Diffusion Forward 4
II.1 Le mouvement Brownien 4
II.2 Formulation SDE (Stochastic Differential Equation) 5
II.3 Outils de calcul stochastique 5

III Résolution de la SDE : trois variantes 7
III.1 Variance Exploding (VE) 7
III.2 Variance Preserving (VP) — Ornstein–Uhlenbeck 7
III.3 DDPM (Denoising Diffusion Probabilistic Models)— formulation discrète 9

IV Formule de Tweedie 10
IV.1 Estimateur MMSE 10
IV.2 Cas VE 10
IV.3 Cas VP/DDPM 11
IV.4 Équivalence des paramétrisations 11

V Apprentissage du Score 12
V.1 Pourquoi le score ? 12
V.2 Denoising Score Matching 12
V.3 Synthèse du processus forward 13

VI Génération d'images 13
VI.1 SDE reverse 13
VI.2 DDPM vs DDIM 13
VI.3 Probability Flow ODE 14

VII Problèmes inverses 14
VII.1 Formulation et exemples 15
VII.2 Pourquoi échantillonner via la SDE reverse ? 15
VII.3 Décomposition du score conditionnel 15
VII.4 Intractabilité du score de mesure 16
VII.5 DPS : approximation Dirac 16
VII.6 ΠGDM : approximation gaussienne 17
VII.7 Synthèse de processus reverse 18

Tentative d'une nouvelle approche 20

VIII Motivation 20

IX Rappels et hypothèses 20

X Score conditionnel en forme fermée 21
X.1 Étape 1 : Tweedie conditionnel appliqué à $p_t(\cdot|y)$ . . . 21
X.2 Étape 2 : loi de $X_0|X_t, Y$ sous les hypothèses ΠGDM . . . 22
X.3 Étape 3 : produit de gaussiennes et complétion du carré . . . 22
X.4 Résultat principal : score conditionnel explicite . . . 24
X.5 Vers l'optimisation variationnelle de r_t^2 et σ_b^2 . . . 24

XI Modèle hiérarchique bayésien 25
XI.1 Variables et structure . . . 25
XI.2 Lois du modèle génératif . . . 25
XI.3 Loi jointe . . . 26
XI.4 Log-vraisemblance jointe . . . 26

XII Approximation variationnelle 27
XII.1 Pourquoi approcher l'a posteriori ? . . . 27
XII.2 Choix de la mesure de dissemblance . . . 27
XII.3 Hypothèse de champ moyen . . . 28

XIII Optimisation dans l'espace des mesures 29
XIII.1 Pourquoi ne pas faire de la descente de gradient classique ? . . . 29
XIII.2 Espaces fonctionnels . . . 30
XIII.3 Différentielle de Gâteaux de l'énergie libre . . . 31
XIII.4 Mise à jour multiplicative par Radon-Nikodym . . . 32
XIII.5 Sous-espace de directions : gradient à mémoire . . . 33
XIII.6 Choix du pas . . . 35
XIII.7 Synthèse de l'algorithme . . . 35
XIII.8 Application à notre cas d'étude . . . 35
XIII.8.1 Rappel de la log-jointe . . . 36
XIII.8.2 Distribution de référence pour τ_b . . . 36
XIII.8.3 Distribution de référence pour τ_r . . . 37
XIII.8.4 Distribution de référence pour $x_{0,i}$ . . . 38
XIII.8.5 Mise à jour EMG-VBA . . . 42

Modèles de Diffusion Génératifs

I Introduction

Un modèle de diffusion génératif repose sur une idée simple : dégrader progressivement les données en ajoutant du bruit, puis apprendre à inverser cette destruction. Le **processus directe** (forward) corrompt une donnée réelle par des ajouts successifs de bruit gaussien jusqu'à obtenir du bruit pur. Le **processus inverse** (reverse), guidé par un réseau de neurones, fait le chemin inverse. Ce compte rendu retrace le cheminement entre autres mathématique. On formalise le processus forward comme une SDE, on la résout sous trois variantes, on introduit la formule de Tweedie et le score, puis on montre comment guider la génération par des mesures y pour résoudre des problèmes inverses en imagerie par exemple (IRM, super-résolution, inpainting).

II Processus de Diffusion Forward

II.1 Le mouvement Brownien

Le mouvement Brownien modélise un bruit continu, gaussien, à incréments indépendants. C'est exactement ce qu'il faut pour corrompre progressivement une image.

Définition II.1.1— Processus de Wiener standard

Les variables aléatoires $(W_t)_{t\geq 0}$ à valeurs dans $\mathbb{R}^n$ est un **processus de Wiener standard** si :

(i) $W_0 = 0$,

(ii) les incréments sont indépendants : pour $0 \leq t_1 < \cdots < t_k$, les variables aléatoires (v.a.) $W_{t_2} - W_{t_1}, \ldots, W_{t_k} - W_{t_{k-1}}$ sont indépendantes,

(iii) les incréments sont gaussiens : $W_t - W_s \sim \mathcal{N}(0, (t-s)\, I_n)$ pour $0 \leq s < t$,

(iv) les trajectoires $t \mapsto W_t$ sont continues.

La propriété (iii) est cruciale : la variance des incréments est proportionnelle au temps, donc l'écart-type croît en $\sqrt{t}$. C'est cette propriété qui fait apparaître les $\sqrt{\cdot}$ dans les formules de diffusion.

II.2 Formulation SDE (Stochastic Differential Equation)

On combine un décalage (drift) déterministe et un bruit brownien dans une équation différentielle stochastique.

Définition II.2.1— SDE forward

Le processus forward est défini par :

$$\boxed{\mathrm{d}X_t = f(X_t, t)\,\mathrm{d}t + g(t)\,\mathrm{d}W_t, \qquad X_0 \sim p_{\text{data}}} \tag{1}$$

où $f(X_t, t)$ est le **drift**, $g(t)$ le **coefficient de diffusion**, et W_t un mouvement Brownien standard (Définition II.1.1).

L'objectif est de résoudre cette SDE : exprimer la loi de $X_t|X_0$. Trois outils de calcul stochastique sont nécessaires.

II.3 Outils de calcul stochastique

Proposition II.3.1— Isométrie d'Itô

Soit $g : [0, T] \to \mathbb{R}$ déterministe avec $\int_0^T g(s)^2\,\mathrm{d}s < \infty$. Alors :

$$\mathbb{E}\left[\left(\int_0^T g(s)\,\mathrm{d}W_s\right)^2\right] = \int_0^T g(s)^2\,\mathrm{d}s \tag{2}$$

Démonstration.

Étape 1 : approximation en escalier. Soit $\pi = \{0 = t_0 < t_1 < \cdots < t_N = T\}$ une partition de $[0, T]$. On approche l'intégrale stochastique par :

$$I_\pi := \int_0^T g(s)dW_s = \sum_{k=0}^{N-1} g(t_k)\,(W_{t_{k+1}} - W_{t_k})$$

Étape 2 : développement de I_π^2.

$$I_\pi^2 = \sum_{k=0}^{N-1}\sum_{j=0}^{N-1} g(t_k)\,g(t_j)\,(W_{t_{k+1}} - W_{t_k})(W_{t_{j+1}} - W_{t_j})$$

Étape 3 : annulation des termes croisés. Pour $k \neq j$, les incréments $(W_{t_{k+1}} - W_{t_k})$ et $(W_{t_{j+1}} - W_{t_j})$ sont indépendants par la Définition II.1.1 (ii). Comme g est déterministe :

$$\mathbb{E}\big[g(t_k)\,g(t_j)\,(W_{t_{k+1}} - W_{t_k})(W_{t_{j+1}} - W_{t_j})\big] = g(t_k)\,g(t_j)\,\underbrace{\mathbb{E}[W_{t_{k+1}} - W_{t_k}]}_{=0}\cdot\mathbb{E}[W_{t_{j+1}} - W_{t_j}] = 0$$

où l'on a utilisé $\mathbb{E}[W_t - W_s] = 0$ par la Définition II.1.1 (iii).

Étape 4 : termes diagonaux. Pour $k = j$:

$$\mathbb{E}\big[g(t_k)^2\,(W_{t_{k+1}} - W_{t_k})^2\big] = g(t_k)^2 \cdot \underbrace{\mathbb{E}\big[(W_{t_{k+1}} - W_{t_k})^2\big]}_{=\Delta t_k} = g(t_k)^2\,\Delta t_k$$

où l'on a utilisé $\mathrm{Var}(W_{t_{k+1}} - W_{t_k}) = t_{k+1} - t_k$ par la Définition II.1.1 (iii).

Étape 5 : passage à la limite.

$$\mathbb{E}[I_\pi^2] = \sum_{k=0}^{N-1} g(t_k)^2\,\Delta t_k \xrightarrow{\Delta t_k \to 0 \quad \forall k} \int_0^T g(s)^2\,\mathrm{d}s$$

par définition de l'intégrale de Riemann. ■

De même, l'espérance est nulle : $\mathbb{E}[I_\pi] = \sum_k g(t_k) \cdot \mathbb{E}[W_{t_{k+1}} - W_{t_k}] = 0$ par la Définition II.1.1 (iii).

Proposition II.3.2— Gaussianité de l'intégrale stochastique

Si $g : [0, T] \to \mathbb{R}$ est déterministe :

$$\int_0^T g(s)\,\mathrm{d}W_s \sim \mathcal{N}\Big(0,\ \int_0^T g(s)^2\,\mathrm{d}s\Big) \tag{3}$$

En dimension n : $\int_0^T g(s)\,\mathrm{d}W_s \sim \mathcal{N}\Big(0, \Big(\int_0^T g(s)^2\,\mathrm{d}s\Big)\,I_n\Big)$.

Démonstration.

Étape 1 : L'approximation $I_\pi = \sum_{k=0}^{N-1} g(t_k)(W_{t_{k+1}} - W_{t_k})$ est une combinaison linéaire de variables gaussiennes indépendantes (les $W_{t_{k+1}} - W_{t_k}$ sont indépendants par la Définition II.1.1 (ii), gaussiens par (iii), et les $g(t_k)$ sont déterministes). Une combinaison linéaire de gaussiennes indépendantes est gaussienne.

Étape 2 : $I_\pi \sim \mathcal{N}(0, \sum_k g(t_k)^2 \Delta t_k)$ (espérance nulle, variance par la Proposition II.3.1).

Étape 3 : La limite en loi d'une suite de gaussiennes est gaussienne (la famille $\mathcal{N}(\mu_n, \sigma_n^2)$ est fermée pour la convergence en loi quand $\mu_n \to \mu$ et $\sigma_n^2 \to \sigma^2$). D'où le résultat.

Étape 4 : En dimension n : les composantes $W_t^{(1)}, \ldots, W_t^{(n)}$ sont des browniens réels indépendants (Définition II.1.1). Chaque composante $\int_0^T g(s)\,\mathrm{d}W_s^{(i)}$ est donc gaussienne centrée de variance $\int g^2\,\mathrm{d}s$, et les composantes sont indépendantes. ■

Proposition II.3.3— Formule d'Itô

Soit X_t un processus d'Itô $\mathrm{d}X_t = \mu_t\,\mathrm{d}t + \sigma_t\,\mathrm{d}W_t$ et $f(x,t) \in C^2 \times C^1$:

$$\mathrm{d}f(X_t, t) = \frac{\partial f}{\partial t}\,\mathrm{d}t + \frac{\partial f}{\partial x}\,\mathrm{d}X_t + \frac{1}{2}\frac{\partial^2 f}{\partial x^2}\,\sigma_t^2\,\mathrm{d}t \tag{4}$$

Le dernier terme vient de $(\mathrm{d}W_t)^2 = \mathrm{d}t$: c'est le Taylor stochastique à l'ordre 2. Ces trois outils en main, on résout la SDE.

III Résolution de la SDE : trois variantes

Trois formulations coexistent. Elles diffèrent par f et g, mais conduisent toutes à : $X_t = \alpha_t X_0 + \sigma_t Z$, un mélange entre signal (α_t décroît) et bruit (σ_t croît).

III.1 Variance Exploding (VE)

Hypothèses III.1.1— VE

$f(X_t, t) = 0$ et $g(t) = \sqrt{\mathrm{d}\sigma_t^2/\mathrm{d}t}$, avec $\sigma_0 = 0$ et (σ_t) croissant.

Résultat III.1.1— Loi marginale VE

$$\boxed{X_t = X_0 + \sigma_t\, Z, \qquad Z \sim \mathcal{N}(0, I_n)} \tag{5}$$

avec $\alpha_t = 1$ et $\sigma_t^2 = \int_0^t g(s)^2\,\mathrm{d}s$.

Démonstration.

Étape 1 : intégration directe. Sous les Hypothèses III.1.1, la SDE (1) se réduit à $\mathrm{d}X_t = g(t)\,\mathrm{d}W_t$. En intégrant de 0 à t :

$$X_t = X_0 + \int_0^t g(s)\,\mathrm{d}W_s$$

Étape 2 : espérance conditionnelle. Sachant X_0, l'intégrale stochastique est une fonctionnelle du brownien W, indépendante de X_0. Par la Proposition II.3.1 (espérance nulle) :

$$\mathbb{E}[X_t \mid X_0] = X_0 + \mathbb{E}\left[\int_0^t g(s)\,\mathrm{d}W_s\right] = X_0$$

Étape 3 : variance conditionnelle. Par l'isométrie d'Itô (Proposition II.3.1), g étant déterministe :

$$\mathrm{Var}(X_t \mid X_0) = \mathbb{E}\left[\left(\int_0^t g(s)\,\mathrm{d}W_s\right)^2\right] = \int_0^t g(s)^2\,\mathrm{d}s = \int_0^t \frac{\mathrm{d}\sigma_s^2}{\mathrm{d}s}\,\mathrm{d}s = \sigma_t^2 - \underbrace{\sigma_0^2}_{=0} = \sigma_t^2$$

Étape 4 : identification de la loi. Par la Proposition II.3.2 (gaussianité de l'intégrale stochastique à noyau déterministe, puis généralisation à $\mathbb{R}^n$), on a :

$$\int_0^t g(s)\,\mathrm{d}W_s \sim \mathcal{N}(0,\, \sigma_t^2\, I_n) \;=\; \sigma_t\, Z, \quad Z \sim \mathcal{N}(0, I_n)$$

D'où $X_t = X_0 + \sigma_t\, Z$. ■

La variance totale de X_t vaut $\mathrm{Var}(X_0) + \sigma_t^2$: elle croît sans borne, d'où le nom *Variance Exploding*.

III.2 Variance Preserving (VP) — Ornstein–Uhlenbeck

Hypothèses III.2.1— VP

$f(X_t, t) = -X_t$ et $g(t) = \sqrt{2}$.

La SDE $\mathrm{d}X_t = -X_t\,\mathrm{d}t + \sqrt{2}\,\mathrm{d}W_t$ est le processus d'Ornstein–Uhlenbeck : le drift $-X_t$ tire vers l'origine, le bruit repousse.

Résultat III.2.1— Loi marginale VP

$$\boxed{X_t = e^{-t}X_0 + \sqrt{1-e^{-2t}}\,Z, \qquad Z \sim \mathcal{N}(0, I_n)} \tag{6}$$

avec $\alpha_t = e^{-t}$ et $\sigma_t = \sqrt{1-e^{-2t}}$.

Démonstration.

Étape 1 : changement de variable. On pose $Y_t = e^t X_t$ et on applique la formule d'Itô (Proposition II.3.3) avec $f(x,t) = e^t x$:

$$\frac{\partial f}{\partial t} = e^t x, \qquad \frac{\partial f}{\partial x} = e^t, \qquad \frac{\partial^2 f}{\partial x^2} = 0$$

$$\begin{aligned}
\mathrm{d}Y_t &= e^t X_t\,\mathrm{d}t + e^t\,\mathrm{d}X_t + \underbrace{\frac{1}{2}\cdot 0 \cdot (\sqrt{2})^2}_{=0}\,\mathrm{d}t \\
&= e^t X_t\,\mathrm{d}t + e^t\big(-X_t\,\mathrm{d}t + \sqrt{2}\,\mathrm{d}W_t\big) \\
&= \cancel{e^t X_t\,\mathrm{d}t} - \cancel{e^t X_t\,\mathrm{d}t} + \sqrt{2}\,e^t\,\mathrm{d}W_t = \sqrt{2}\,e^t\,\mathrm{d}W_t
\end{aligned} \tag{7}$$

Le drift a disparu : Y_t suit un brownien pur de coefficient $\sqrt{2}\,e^t$.

Étape 2 : intégration.

$$Y_t = Y_0 + \sqrt{2}\int_0^t e^s\,\mathrm{d}W_s = X_0 + \sqrt{2}\int_0^t e^s\,\mathrm{d}W_s$$

En divisant par e^t :

$$X_t = e^{-t}\,X_0 + \sqrt{2}\,e^{-t}\int_0^t e^s\,\mathrm{d}W_s$$

Étape 3 : espérance. L'intégrale stochastique est d'espérance nulle (Proposition II.3.1) :

$$\mathbb{E}[X_t \mid X_0] = e^{-t}\,X_0$$

Étape 4 : variance. Le noyau $\tilde{g}(s) = \sqrt{2}\,e^s$ est déterministe. Par l'isométrie d'Itô (Proposition II.3.1) :

$$\begin{aligned}
\mathrm{Var}(X_t \mid X_0) &= e^{-2t}\cdot\mathbb{E}\left[\left(\sqrt{2}\int_0^t e^s\,\mathrm{d}W_s\right)^2\right] = e^{-2t}\cdot 2\int_0^t e^{2s}\,\mathrm{d}s \\
&= e^{-2t}\cdot 2\cdot\frac{e^{2t}-1}{2} = 1 - e^{-2t}
\end{aligned} \tag{8}$$

Étape 5 : identification et vérification. Par la Proposition II.3.2 : $X_t \mid X_0 \sim \mathcal{N}(e^{-t}X_0,\ (1-e^{-2t})\, I_n)$. On vérifie : $\alpha_t^2 + \sigma_t^2 = e^{-2t} + 1 - e^{-2t} = 1$. Si $\mathrm{Var}(X_0) = 1$, alors $\mathrm{Var}(X_t) = 1$ à tout instant d'où le nom *Variance Preserving*. ■

III.3 DDPM (Denoising Diffusion Probabilistic Models)— formulation discrète

Définition III.3.1— Processus forward DDPM

Chaîne de Markov : $q(X_t|X_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}\, X_{t-1},\ \beta_t I_n)$ avec $\alpha_t = 1-\beta_t$ et $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$.

Résultat III.3.1— Loi marginale DDPM

$$\boxed{X_t = \sqrt{\bar{\alpha}_t}\, X_0 + \sqrt{1-\bar{\alpha}_t}\, Z, \qquad Z \sim \mathcal{N}(0, I_n)} \tag{9}$$

Démonstration.

Par récurrence sur t.

Initialisation ($t = 1$). Par la Définition III.3.1 : $X_1 = \sqrt{\alpha_1}\, X_0 + \sqrt{\beta_1}\, \epsilon_1$ avec $\epsilon_1 \sim \mathcal{N}(0, I_n)$. Comme $\bar{\alpha}_1 = \alpha_1$ et $1 - \bar{\alpha}_1 = \beta_1$, c'est bien la forme attendue.

Hérédité. Supposons $X_t = \sqrt{\bar{\alpha}_t}\, X_0 + \sqrt{1-\bar{\alpha}_t}\, Z_t$ avec $Z_t \sim \mathcal{N}(0, I_n)$.

Étape 1 : substitution. Par la Définition III.3.1 :

$$X_{t+1} = \sqrt{\alpha_{t+1}}\, X_t + \sqrt{\beta_{t+1}}\, \epsilon_{t+1} = \sqrt{\alpha_{t+1}\bar{\alpha}_t}\, X_0 + \sqrt{\alpha_{t+1}(1-\bar{\alpha}_t)}\, Z_t + \sqrt{\beta_{t+1}}\, \epsilon_{t+1}$$

Étape 2 : somme de gaussiennes indépendantes. Z_t dépend de $\epsilon_1, \ldots, \epsilon_t$ et $\epsilon_{t+1} \sim \mathcal{N}(0, I_n)$ en est indépendant. Les deux termes de bruit sont donc des gaussiennes centrées indépendantes. Leur somme est gaussienne centrée de variance :

$$\alpha_{t+1}(1-\bar{\alpha}_t) + \beta_{t+1}$$

Étape 3 : calcul de la variance.

$$\begin{aligned}
\alpha_{t+1}(1-\bar{\alpha}_t) + \beta_{t+1} &= \alpha_{t+1} - \alpha_{t+1}\bar{\alpha}_t + \beta_{t+1} \\
&= \alpha_{t+1} - \underbrace{\alpha_{t+1}\bar{\alpha}_t}_{=\bar{\alpha}_{t+1}} + \underbrace{(1-\alpha_{t+1})}_{=\beta_{t+1}} \\
&= 1 - \bar{\alpha}_{t+1}
\end{aligned} \tag{10}$$

Étape 4 : conclusion. $X_{t+1} = \sqrt{\bar{\alpha}_{t+1}}\, X_0 + \sqrt{1-\bar{\alpha}_{t+1}}\, Z_{t+1}$ avec $Z_{t+1} \sim \mathcal{N}(0, I_n)$. ■

Remarque— Lien VP–DDPM

En limite continue $\Delta t \to 0$ avec $\beta_t \to \beta(t)\Delta t$, on retrouve la VP-SDE : DDPM est une discrétisation de l'Ornstein–Uhlenbeck.

IV Formule de Tweedie

On a $X_t|X_0$ pour chaque variante. Pour *générer*, il faut le chemin inverse : retrouver X_0 à partir de X_t bruité. La formule de Tweedie relie l'estimateur optimal au score.

IV.1 Estimateur MMSE

Résultat IV.1.1— Estimateur MMSE
Parmi tous les estimateurs $\hat{X}_0(X_t)$, celui qui minimise $\mathrm{MSE}[\hat{X}_0] = \mathbb{E}[\|\hat{X}_0 - X_0\|^2]$ est : $\hat{X}_0^* = \mathbb{E}[X_0|X_t]$.

Démonstration.
Étape 1 : décomposition biais-variance. Soit $h(X_t)$ un estimateur quelconque. On écrit $h - X_0 = (h - \mathbb{E}[X_0|X_t]) + (\mathbb{E}[X_0|X_t] - X_0)$ et on développe :

$$\mathbb{E}[\|h - X_0\|^2] = \underbrace{\mathbb{E}[\|h - \mathbb{E}[X_0|X_t]\|^2]}_{A \geq 0} + \underbrace{\mathbb{E}[\|\mathbb{E}[X_0|X_t] - X_0\|^2]}_{B} + 2C$$

où $C = \mathbb{E}[\langle h - \mathbb{E}[X_0|X_t],\ \mathbb{E}[X_0|X_t] - X_0\rangle]$.
Étape 2 : annulation du terme croisé par la propriété de la tour.

$$C = \mathbb{E}[\mathbb{E}[\langle h - \mathbb{E}[X_0|X_t],\ \mathbb{E}[X_0|X_t] - X_0\rangle \mid X_t]]$$

Sachant X_t, le vecteur $h(X_t) - \mathbb{E}[X_0|X_t]$ est déterministe. Il sort du produit scalaire :

$$= \mathbb{E}\left[\left\langle h - \mathbb{E}[X_0|X_t],\ \underbrace{\mathbb{E}[\mathbb{E}[X_0|X_t] - X_0 \mid X_t]}_{=\mathbb{E}[X_0|X_t] - \mathbb{E}[X_0|X_t] = 0}\right\rangle\right] = 0$$

Étape 3 : conclusion. $\mathrm{MSE}[h] = A + B \geq B = \mathrm{MSE}[\mathbb{E}[X_0|X_t]]$. Égalité ssi $A = 0$, i.e. $h = \mathbb{E}[X_0|X_t]$. ■

IV.2 Cas VE

Résultat IV.2.1— Formule de Tweedie — VE
Sous les Hypothèses III.1.1, $X_t = X_0 + \sigma_t Z$. Alors :

$$\boxed{\mathbb{E}[X_0 \mid X_t] = X_t + \sigma_t^2 \nabla_{X_t} \log p_t(X_t)} \tag{11}$$

où p_t est la densité marginale de X_t et $\nabla_{X_t} \log p_t$ son score.

Pour débruiter, il suffit de faire un pas dans la direction du score, pondéré par σ_t^2. Plus le bruit est fort, plus le pas est grand.

Démonstration.

Étape 1 : densité marginale. Par le Résultat III.1.1 : $X_t|X_0 \sim \mathcal{N}(X_0, \sigma_t^2 I_n)$. La densité marginale est :

$$p_t(x_t) = \int p_{\text{data}}(x_0) \underbrace{\frac{1}{(2\pi\sigma_t^2)^{n/2}} \exp\left(-\frac{\|x_t - x_0\|^2}{2\sigma_t^2}\right)}_{p(x_t|x_0)} \mathrm{d}x_0$$

Étape 2 : gradient du noyau gaussien.

$$\nabla_{x_t} p(x_t \mid x_0) = p(x_t \mid x_0) \cdot \nabla_{x_t}\left(-\frac{\|x_t - x_0\|^2}{2\sigma_t^2}\right) = p(x_t \mid x_0) \cdot \frac{x_0 - x_t}{\sigma_t^2}$$

Étape 3 : gradient de la marginale. En dérivant sous le signe intégral (justifié par convergence dominée, car le noyau gaussien est C^∞ et à décroissance rapide) :

$$\nabla_{x_t} p_t(x_t) = \int p_{\text{data}}(x_0)\, \nabla_{x_t} p(x_t \mid x_0)\, \mathrm{d}x_0 = \frac{1}{\sigma_t^2} \int (x_0 - x_t)\, p(x_t \mid x_0)\, p_{\text{data}}(x_0)\, \mathrm{d}x_0$$

Étape 4 : identification par Bayes. En divisant par $p_t(x_t)$:

$$\nabla_{x_t} \log p_t(x_t) = \frac{1}{\sigma_t^2} \int (x_0 - x_t) \underbrace{\frac{p(x_t \mid x_0)\, p_{\text{data}}(x_0)}{p_t(x_t)}}_{=p(x_0|x_t)\ \text{(Bayes)}} \mathrm{d}x_0 = \frac{\mathbb{E}[X_0 \mid X_t] - x_t}{\sigma_t^2}$$

Étape 5 : réarrangement. $\mathbb{E}[X_0 \mid X_t] = X_t + \sigma_t^2 \nabla_{X_t} \log p_t(X_t)$. ■

IV.3 Cas VP/DDPM

Résultat IV.3.1— Formule de Tweedie — VP/DDPM

Sous VP/DDPM, $X_t = \sqrt{\bar{\alpha}_t}\, X_0 + \sqrt{1 - \bar{\alpha}_t}\, Z$. Alors :

$$\boxed{\mathbb{E}[X_0 \mid X_t] = \frac{1}{\sqrt{\bar{\alpha}_t}}(X_t + (1 - \bar{\alpha}_t)\, \nabla_{X_t} \log p_t(X_t))} \tag{12}$$

Démonstration.

Étape 1 : réduction au cas VE. On pose $\tilde{X}_0 = \sqrt{\bar{\alpha}_t}\, X_0$ et $\tilde{\sigma}_t = \sqrt{1 - \bar{\alpha}_t}$. Alors $X_t = \tilde{X}_0 + \tilde{\sigma}_t Z$, qui est exactement le modèle VE pour la variable $\tilde{X}_0$.

Étape 2 : application du résultat IV.2.1. $\mathbb{E}[\tilde{X}_0 \mid X_t] = X_t + (1 - \bar{\alpha}_t)\, \nabla_{X_t} \log p_t(X_t)$.

Étape 3 : retour à X_0. Par linéarité : $\mathbb{E}[\tilde{X}_0 \mid X_t] = \sqrt{\bar{\alpha}_t}\, \mathbb{E}[X_0 \mid X_t]$. En divisant par $\sqrt{\bar{\alpha}_t} > 0$, on obtient le résultat. ■

On note $\hat{x}_0(x_t)$ l'estimateur de Tweedie dans la suite.

IV.4 Équivalence des paramétrisations

Résultat IV.4.1— Équivalence score–bruit–denoiser

Les trois formulations suivantes sont équivalentes :

- **Score :** $s_\theta(x_t, t) \approx \nabla_{x_t} \log p_t(x_t)$
- **Bruit :** $\epsilon_\theta(x_t, t) \approx Z$, avec $s_\theta = -\epsilon_\theta / \sqrt{1 - \bar{\alpha}_t}$
- **Denoiser :** $D_\theta(x_t, t) \approx \mathbb{E}[X_0 | X_t]$

V Apprentissage du Score

Tout repose sur $\nabla \log p_t$ (résultats IV.2.1–IV.3.1). Mais cette quantité dépend de p_t, qu'on ne connaît pas. Comment l'apprendre ?

V.1 Pourquoi le score ?

Définition V.1.1— Score d'une distribution

Le **score** de $p(x)$ est $s(x) = \nabla_x \log p(x)$. Propriété clé : si $p(x) = \tilde{p}(x)/Z$, alors $\nabla_x \log p = \nabla_x \log \tilde{p}$ (la constante Z disparaît).

Géométriquement, c'est un champ de vecteurs pointant vers les régions de haute densité. Son intérêt est qu'il évite $Z = \int \tilde{p} \, \mathrm{d}x$, intractable en grande dimension.

V.2 Denoising Score Matching

L'objectif naïf serait $\mathcal{L}_{\mathrm{SM}} = \mathbb{E}_{p_t}[\|s_\theta - \nabla \log p_t\|^2]$, mais le vrai score est inconnu. Le DSM (Vincent, 2011) le contourne.

Résultat V.2.1— Denoising Score Matching

L'objectif $\mathcal{L}_{\mathrm{SM}}$ et l'objectif :

$$\mathcal{L}_{\mathrm{DSM}}(\theta) = \mathbb{E}_{x_0 \sim p_{data}, z \sim \mathcal{N}(0,I)} \left[\|s_\theta(x_t, t) - \nabla_{x_t} \log p_t(x_t \mid x_0)\|^2 \right] \tag{13}$$

ont le même minimiseur. Ici $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon$ et $\nabla_{x_t} \log p(x_t | x_0) = -\epsilon / \sqrt{1 - \bar{\alpha}_t}$.

Démonstration.

Étape 1 : développement des deux objectifs.

$$\mathcal{L}_{\mathrm{DSM}} = \mathbb{E}[\|s_\theta\|^2] - 2\,\mathbb{E}[\langle s_\theta, \nabla \log p(x_t|x_0) \rangle] + \mathbb{E}[\|\nabla \log p(x_t|x_0)\|^2] \tag{14}$$

$$\mathcal{L}_{\mathrm{SM}} = \mathbb{E}[\|s_\theta\|^2] - 2\,\mathbb{E}[\langle s_\theta, \nabla \log p_t(x_t) \rangle] + \mathbb{E}[\|\nabla \log p_t(x_t)\|^2] \tag{15}$$

Les derniers termes sont indépendants de θ. Il suffit de montrer que les termes croisés sont identiques.

Étape 2 : identité clé. On montre que $\mathbb{E}_{x_0}[\nabla_{x_t} \log p(x_t|x_0) \mid x_t] = \nabla_{x_t} \log p_t(x_t)$:

$$\begin{aligned}\mathbb{E}_{x_0}[\nabla \log p(x_t|x_0) \mid x_t] &= \int \frac{\nabla_{x_t} p(x_t|x_0)}{p(x_t|x_0)} \cdot \frac{p(x_t|x_0)\, p_{\text{data}}(x_0)}{p_t(x_t)}\, \mathrm{d}x_0 \\ &= \frac{1}{p_t(x_t)} \int \nabla_{x_t} p(x_t|x_0)\, p_{\text{data}}(x_0)\, \mathrm{d}x_0 = \frac{\nabla_{x_t} p_t(x_t)}{p_t(x_t)} = \nabla_{x_t} \log p_t(x_t) \quad (16)\end{aligned}$$

Étape 3 : égalité des termes croisés par la tour.

$$\mathbb{E}[\langle s_\theta,\, \nabla \log p(x_t|x_0)\rangle] = \mathbb{E}_{x_t}\left[\langle s_\theta,\, \underbrace{\mathbb{E}_{x_0}[\nabla \log p(x_t|x_0) \mid x_t]}_{=\nabla \log p_t(x_t)}\rangle\right] = \mathbb{E}[\langle s_\theta,\, \nabla \log p_t\rangle]$$

Étape 4 : conclusion. $\mathcal{L}_{\text{DSM}} - \mathcal{L}_{\text{SM}}$ est une constante indépendante de θ. Les deux ont le même minimiseur. ■

V.3 Synthèse du processus forward

Les trois variantes partagent la même structure : $X_t = \alpha_t X_0 + \sigma_t Z$ avec $Z \sim \mathcal{N}(0, I_n)$. Le signal (α_t) décroît tandis que le bruit (σ_t) croît. La formule de Tweedie (section IV) relie ensuite l'estimateur optimal $\mathbb{E}[X_0|X_t]$ au score $\nabla \log p_t$, qui est appris par un réseau de neurones. Le schéma ci-dessous résume l'ensemble de la pipeline forward.

VI Génération d'images

VI.1 SDE reverse

Théorème VI.1.1— Anderson, 1982 (admis [5])
Toute SDE forward (Définition II.2.1) admet une SDE reverse :

$$\boxed{\mathrm{d}X_t = \left[f(X_t, t) - g(t)^2\, \nabla_{X_t} \log p_t(X_t)\right] \mathrm{d}t + g(t)\, \mathrm{d}\bar{W}_t} \quad (17)$$

Le terme $-g^2 \nabla \log p_t$ pousse X_t vers les régions de haute densité. L'algorithme : $X_T \sim \mathcal{N}(0, I)$, discrétiser de T à 0 en remplaçant le score par s_θ (Théorème V.2.1).

VI.2 DDPM vs DDIM

DDPM : discrétisation stochastique, $T = 1000$ pas :

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\, \epsilon_\theta\right) + \sigma_t z, \quad z \sim \mathcal{N}(0, I)$$

DDIM : déterministe, 10–50 pas : $x_{t-1} = \sqrt{\bar{\alpha}_{t-1}}\, \hat{x}_0 + \sqrt{1-\bar{\alpha}_{t-1}}\, \epsilon_\theta$ où $\hat{x}_0$ est donné par le résultat IV.3.1.

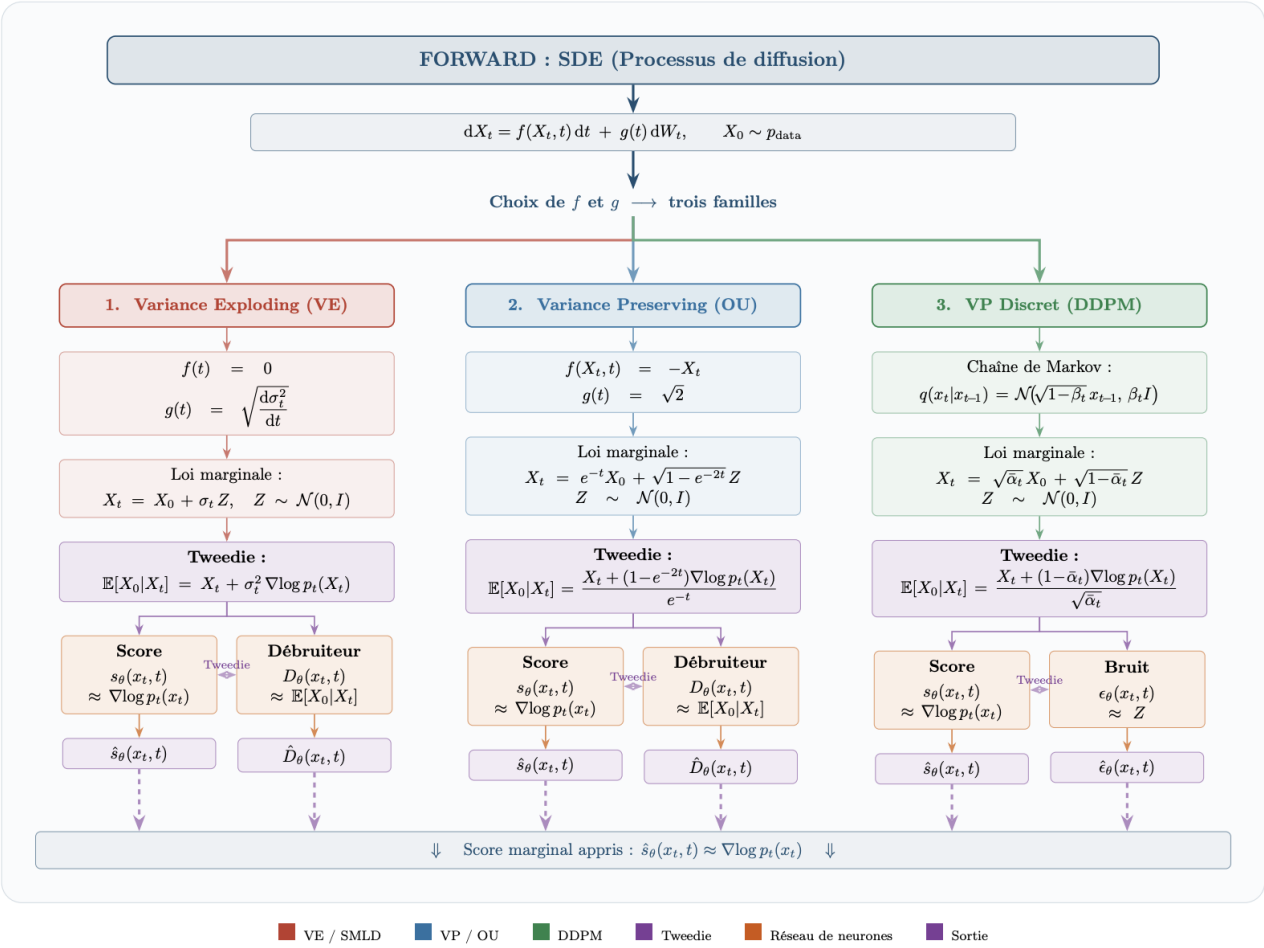

FIGURE 1 – Pipeline forward : de la SDE aux trois variantes, avec le lien Tweedie entre score et denoiser.

VI.3 Probability Flow ODE

Équivalent déterministe (mêmes marginales) : $dX_t = [f - \frac{1}{2}g^2 \nabla \log p_t]\,dt$. DDIM en est une discrétisation. Le facteur $\frac{1}{2}$ compense l'absence du terme de bruit.

VII Problèmes inverses

Le processus reverse (Théorème VI.1.1) permet de générer des images en intégrant la SDE inverse avec le score appris s_θ. Pour résoudre un **problème inverse**, autrement dit, pour reconstruire x_0 à partir de mesures dégradées y, on remplace le score inconditionnel par le score conditionnel $\nabla \log p_t(x_t|y)$.

VII.1 Formulation et exemples

Dans de nombreuses applications en imagerie, on n'observe pas directement l'image x_0 mais une version dégradée y. Le modèle de diffusion, entraîné sur des images propres, fournit un a priori puissant pour reconstruire x_0 à partir de y.

Définition VII.1.1— Problème inverse linéaire

$$y = Ax_0 + \sigma_b\, b, \qquad b \sim \mathcal{N}(0, I_m) \tag{18}$$

où $A \in \mathbb{R}^{m\times n}$ est un opérateur linéaire connu et $\sigma_b > 0$ le niveau de bruit de mesure.

Ce formalisme couvre un large spectre de problèmes :

- **Super-résolution** ($\times 4$) : A est un sous-échantillonnage (moyennage de blocs 4×4). On observe une image basse résolution, on veut reconstruire les détails fins.
- **IRM accélérée** : $A = MF$ où F est la transformée de Fourier 2D et M un masque binaire qui ne retient que certaines fréquences. On observe un sous-ensemble des coefficients de Fourier.
- **Inpainting** : A est un masque diagonal ($A_{ii} = 0$ pour les pixels manquants, 1 sinon). On observe une image avec des régions occultées.
- **Défloutage** : A est une convolution avec un noyau de flou (gaussien, mouvement). On observe une image floue.

On veut échantillonner l' **a posteriori** $p(x_0|y)$: l'ensemble des images naturelles compatibles avec les mesures y.

VII.2 Pourquoi échantillonner via la SDE reverse ?

On dispose du score inconditionnel $\nabla \log p_t$ (via le denoiser entraîné, résultat V.2.1). L'idée est de guider la SDE reverse (Théorème VI.1.1) par les mesures y en remplaçant le score inconditionnel par le score conditionnel :

$$\mathrm{d}\tilde{X}_t = \Big[-f + g^2\, \nabla_x \log p_{T-t}(\tilde{X}_t \mid y)\Big]\,\mathrm{d}t + g\,\mathrm{d}\bar{W}_t, \qquad \tilde{X}_0 \sim p_T(\cdot|y) \approx \mathcal{N}(0, I) \tag{19}$$

Par le même argument qu'Anderson, les marginales de ce processus sont $p_t(\cdot|y)$, et au temps final on obtient $p_0(\cdot|y) = p(x_0|y)$.

Pourquoi ne pas faire du MCMC directement sur $p(x_0|y)$? La SDE de diffusion offre un **schedule multiscale** naturel : à temps élevé (bruit fort), on résout les grandes structures ; à temps faible (bruit faible), on affine les détails. En pratique, quelques centaines de pas suffisent, contre des millions pour un MCMC naïf en dimension $n \approx 256 \times 256 \times 3 \approx 200\,000$.

VII.3 Décomposition du score conditionnel

Par la règle de Bayes $p(x_t|y) \propto p_t(x_t)\, p(y|x_t)$, le score conditionnel se décompose :

$$\boxed{\nabla_{x_t} \log p(x_t|y) = \underbrace{\nabla_{x_t} \log p_t(x_t)}_{\text{score a priori } (s_\theta)} + \underbrace{\nabla_{x_t} \log p(y|x_t)}_{\text{score likelihood}}} \tag{20}$$

Le premier terme est connu : c'est le score appris par le denoiser (résultat V.2.1). Le second est intractable.

VII.4 Intractabilité du score de mesure

Proposition VII.4.1— Forme du score de mesure

$$p(y|x_t) = \int p(y|x_0) \underbrace{p(x_0|x_t)}_{\text{impossible à calculer}} \mathrm{d}x_0 \tag{21}$$

Démonstration.

Étape 1 : marginalisation. $p(y|x_t) = \int p(y, x_0|x_t)\,\mathrm{d}x_0 = \int p(y|x_0, x_t)\,p(x_0|x_t)\,\mathrm{d}x_0$.

Étape 2 : structure de Markov. Y ne dépend de X_t qu'à travers X_0 (chaîne $Y \leftarrow X_0 \rightarrow X_t$), donc $p(y|x_0, x_t) = p(y|x_0)$.

Étape 3 : conclusion. $p(y|x_t) = \int p(y|x_0)\,p(x_0|x_t)\,\mathrm{d}x_0$. ■

Le terme $p(y|x_0) = \mathcal{N}(y; Ax_0, \sigma_b^2 I)$ est connu. Mais $p(x_0|x_t)$ est l'**a posteriori de débruitage** : par Bayes, $p(x_0|x_t) \propto p(x_t|x_0)\,p_{\text{data}}(x_0)$, et l'a priori p_{data} (distribution des images naturelles) est un objet complexe, multimodal, en dimension $n \approx 200\,000$. L'intégrale est impossible à calculer.

Le résultat IV.1.1 ne donne que $\mathbb{E}[X_0|X_t]$ (la moyenne), pas la distribution entière $p(x_0|x_t)$. Toutes les méthodes ci-dessous approximent $p(x_0|x_t)$ par une distribution simple. Dans ce compte rendu, nous ne détaillerons que DPS et ΠGDM, mais la figure 2 propose un panorama un peu plus large des approches possibles.

Remarque— Tweedie conditionnel

En appliquant Tweedie à la loi conditionnelle $p_t(\cdot|y)$ au lieu de p_t, on a :

$$\mathbb{E}[X_0|X_t, Y = y] = \underbrace{\mathbb{E}[X_0|X_t]}_{\hat{x}_0 \text{ (denoiser)}} + \sigma_t^2\,\nabla_{x_t} \log p(y|x_t)$$

VII.5 DPS : approximation Dirac

Chung et al. (2023) posent l'approximation la plus brutale : $p(x_0|x_t) \approx \delta(x_0 - \hat{x}_0)$, où $\hat{x}_0 = \mathbb{E}[X_0|X_t]$ est le denoiser de Tweedie.

Résultat VII.5.1— DPS — Diffusion Posterior Sampling

$$\nabla_{x_t} \log p(y|x_t) \approx \nabla_{x_t} \log p(y|\hat{x}_0) \tag{22}$$

Démonstration.

Étape 1 : approximation Dirac. En substituant $p(x_0|x_t) \approx \delta(x_0 - \hat{x}_0)$ dans la Proposition VII.4.1 :

$$p(y|x_t) \approx \int p(y|x_0)\,\delta(x_0 - \hat{x}_0)\,\mathrm{d}x_0 = p(y|\hat{x}_0)$$

Étape 2 : gradient. $\hat{x}_0 = \hat{x}_0(x_t)$ dépend de x_t via Tweedie. Par la règle de la chaîne :

$$\nabla_{x_t} \log p(y|\hat{x}_0) = \left(\frac{\partial \hat{x}_0}{\partial x_t}\right)^T \nabla_{\hat{x}_0} \log p(y|\hat{x}_0)$$

Étape 3 : cas linéaire. Pour $y = Ax_0 + \sigma_b b$, $p(y|\hat{x}_0) = \mathcal{N}(y; A\hat{x}_0, \sigma_b^2 I)$:

$$\nabla_{x_t} \log p(y|\hat{x}_0) = \frac{1}{\sigma_b^2}\left(\frac{\partial \hat{x}_0}{\partial x_t}\right)^T A^T(y - A\hat{x}_0)$$

Par Tweedie, $\hat{x}_0 = x_t + \sigma_t^2 \nabla \log p_t(x_t)$, donc $\frac{\partial \hat{x}_0}{\partial x_t} = I_n + \sigma_t^2\, \nabla^2_{x_t} \log p_t(x_t)$.

Étape 4 : limitation. L'approximation Dirac ignore toute l'incertitude de $p(x_0|x_t)$: quand t est grand (σ_t grand), $\hat{x}_0$ est un estimateur très bruité de X_0, et concentrer toute la masse en ce point est une approximation grossière. ■

VII.6 ΠGDM : approximation gaussienne

Song et al. (2023) améliorent DPS en modélisant l'incertitude du denoiser.

Hypothèses VII.6.1— ΠGDM — Song et al., 2023

(H1) $p(x_0|x_t) \approx \mathcal{N}(\hat{x}_0,\ r_t^2 I_n)$ (gaussienne isotrope de rayon r_t)

(H2) $y = Ax_0 + \sigma_b b$ (Définition VII.1.1)

Le paramètre r_t^2 capture l'incertitude du denoiser : grand quand t est grand (beaucoup de bruit, $\hat{x}_0$ imprécis), petit quand $t \to 0$ (peu de bruit, $\hat{x}_0 \to x_0$).

Résultat VII.6.1— Vraisemblance ΠGDM

$$p(y|x_t) \approx \mathcal{N}(A\hat{x}_0,\ \Sigma_y)\,, \qquad \Sigma_y = \sigma_b^2 I_m + r_t^2\, AA^T \tag{23}$$

Démonstration.

Étape 1 : modèle conditionnel. Sous (H1) : $x_0|x_t \sim \mathcal{N}(\hat{x}_0, r_t^2 I_n)$. Sous (H2) : $y|x_0 \sim \mathcal{N}(Ax_0, \sigma_b^2 I_m)$.

Étape 2 : espérance de $y|x_t$. Par la tour : $\mathbb{E}[y|x_t] = \mathbb{E}[\mathbb{E}[y|x_0]|x_t] = \mathbb{E}[Ax_0|x_t] = A\hat{x}_0$.

Étape 3 : variance de $y|x_t$. Par la loi de la variance totale :

$$\mathrm{Var}(y|x_t) = \underbrace{\mathrm{Var}(\mathbb{E}[y|x_0]|x_t)}_{=\mathrm{Var}(Ax_0|x_t)=A(r_t^2 I)A^T} + \underbrace{\mathbb{E}[\mathrm{Var}(y|x_0)|x_t]}_{=\sigma_b^2 I_m} = r_t^2 AA^T + \sigma_b^2 I_m$$

Étape 4 : loi résultante. $y|x_t$ est une transformation affine de gaussiennes (sous les hypothèses), donc gaussien : $y|x_t \sim \mathcal{N}(A\hat{x}_0, \Sigma_y)$.

Étape 5 : gradient. Par la règle de la chaîne ($x_t \to \hat{x}_0(x_t) \to \log p$) :

$$\nabla_{x_t} \log p(y|x_t) = \left(\frac{\partial \hat{x}_0}{\partial x_t}\right)^T A^T \Sigma_y^{-1}(y - A\hat{x}_0)$$

Étape 6 : inversion par Woodbury. Pour éviter d'inverser $\Sigma_y \in \mathbb{R}^{m\times m}$:

$$(\sigma_b^2 I + r_t^2 AA^T)^{-1} = \frac{1}{\sigma_b^2}\left(I - \frac{r_t^2}{\sigma_b^2} A\left(I + \frac{r_t^2}{\sigma_b^2} A^T A\right)^{-1} A^T\right)$$

ce qui ramène à l'inversion d'une matrice $n \times n$ au lieu de $m \times m$ (ce qui reste tout de même embêtant, car il reste toujours à inverser une matrice). ■

VII.7 Synthèse de processus reverse

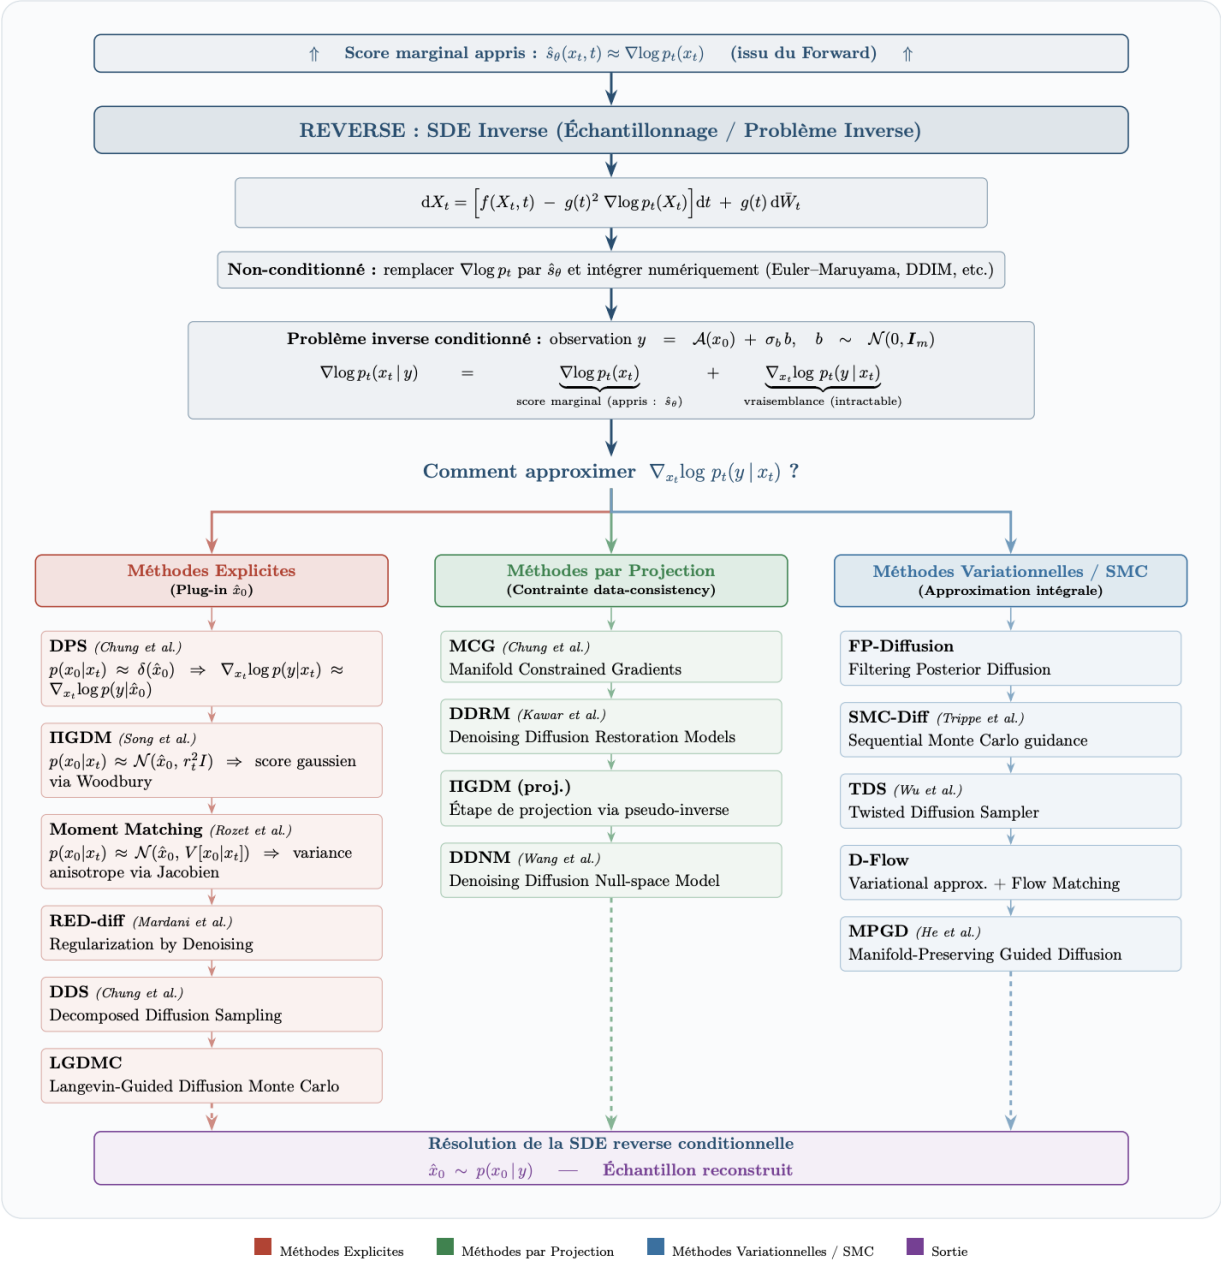

FIGURE 2 – Pipeline reverse conditionnée : décomposition du score conditionnel et les trois familles de méthodes d'approximation

Tentative d'une nouvelle approche

VIII Motivation

La partie I a montré que certaines méthodes de résolution de problèmes inverses par diffusion (DPS et ΠGDM) partagent une difficulté commune : elles dépendent d'hyperparamètres (r_t^2, σ_b^2, step size) fixés manuellement. En pratique, un mauvais réglage dégrade significativement la reconstruction.

L'idée de cette partie est de repartir du cadre ΠGDM (Résultat VII.6.1) et d'exprimer le score conditionnel $\nabla_{x_t} \log p_t(x_t|y)$ sous forme explicite, ce qui permettra potentiellement ensuite d'optimiser r_t^2 et σ_b^2 par inférence variationnelle au lieu de les fixer à la main.

IX Rappels et hypothèses

On se place dans le cadre VP-DDPM (Résultat III.3.1) pour fixer les notations.

Rappel— Loi marginale forward (VP-DDPM)

$$X_t = \sqrt{\bar{\alpha}_t}\, X_0 + \sqrt{1-\bar{\alpha}_t}\, Z, \qquad Z \sim \mathcal{N}(0, I_n) \tag{24}$$

En particulier : $X_t|X_0 \sim \mathcal{N}(\sqrt{\bar{\alpha}_t}\, X_0,\ (1-\bar{\alpha}_t)\, I_n)$.

Rappel— Tweedie conditionnel (VP-DDPM)

Le score de la marginale p_t et celui de la conditionnelle $p_t(\cdot|x_0)$ s'écrivent :

$$\nabla_{x_t} \log p_t(x_t|x_0) = \frac{\sqrt{\bar{\alpha}_t}\, x_0 - x_t}{1-\bar{\alpha}_t} \tag{25}$$

$$\nabla_{x_t} \log p_t(x_t) = \frac{\sqrt{\bar{\alpha}_t}\, \mathbb{E}[X_0|X_t = x_t] - x_t}{1-\bar{\alpha}_t} \tag{26}$$

On note $\hat{x}_0(x_t) = \mathbb{E}[X_0|X_t = x_t]$ le denoiser de Tweedie, approché par le réseau s_θ.

Hypothèses IX.0.1— ΠGDM — approximation gaussienne isotrope

$$X_0 \mid X_t = x_t \;\sim\; \mathcal{N}\big(\hat{x}_0(x_t),\; r_t^2\, I_n\big) \tag{H1}$$

Hypothèses IX.0.2— Problème inverse linéaire gaussien

$$y = A\, x_0 + b, \qquad b \sim \mathcal{N}(0,\, \sigma_b^2\, I_m) \tag{H2}$$

Ces deux hypothèses impliquent la structure de dépendance suivante :

Rappel— Dépendances

(D1) $y = f(x_0, \sigma_b^2)$ (par H2)
(D2) $x_0 \sim g(x_t, r_t^2)$ (par H1)
(D3) $x_t = h(x_0, \bar{\alpha}_t)$ (par (24))

En particulier, la chaîne de Markov $Y \leftarrow X_0 \rightarrow X_t$ implique $Y \perp\!\!\!\perp X_t \mid X_0$: les mesures y ne dépendent pas directement de x_t, seulement à travers x_0.

X Score conditionnel en forme fermée

L'objectif est d'exprimer $\nabla_{x_t} \log p_t(x_t|y)$ de manière exploitable algorithmiquement.

X.1 Étape 1 : Tweedie conditionnel appliqué à $p_t(\cdot|y)$

Proposition X.1.1— Score conditionnel via Tweedie

En appliquant la formule de Tweedie à la distribution conditionnelle $p_t(\cdot|y)$:

$$\boxed{\nabla_{x_t} \log p_t(x_t|y) = \frac{\sqrt{\bar{\alpha}_t}\, \mathbb{E}[X_0|X_t = x_t,\, Y = y] - x_t}{1 - \bar{\alpha}_t}} \tag{27}$$

Démonstration.

Étape 1 : marginalisation.

$$p_t(x_t|y) = \int p_t(x_t, x_0|y)\, \mathrm{d}x_0 = \int \frac{p(y|x_0)\, p_t(x_t|x_0)\, p(x_0)}{p(y)}\, \mathrm{d}x_0$$

où l'on a utilisé $p(y|x_0, x_t) = p(y|x_0)$ (chaîne de Markov $Y \leftarrow X_0 \rightarrow X_t$) et la décomposition $p_t(x_t, x_0) = p_t(x_t|x_0)\, p(x_0)$ (D1).

Étape 2 : gradient.

En dérivant sous l'intégrale par rapport à x_t, seul le terme $p_t(x_t|x_0)$ dépend de x_t :

$$\nabla_{x_t} p_t(x_t|y) = \int \mathrm{cte} \cdot p(y|x_0) \cdot \nabla_{x_t} p_t(x_t|x_0) \cdot p(x_0)\, \mathrm{d}x_0$$

Or,

$$\nabla_{x_t} \log p_t(x_t|x_0) = \frac{\nabla_{x_t} p_t(x_t|x_0)}{p_t(x_t|x_0)}$$

Et par (25) :

$$\nabla_{x_t} p_t(x_t|x_0) = p_t(x_t|x_0) \cdot \frac{\sqrt{\bar{\alpha}_t}\, x_0 - x_t}{1 - \bar{\alpha}_t}$$

Donc :

$$\nabla_{x_t} p_t(x_t|y) = \int \text{cte} \cdot p(y|x_0) \cdot p_t(x_t|x_0) \cdot p(x_0) \cdot \frac{\sqrt{\bar{\alpha}_t}\, x_0 - x_t}{1 - \bar{\alpha}_t}\, \mathrm{d}x_0$$

Étape 3 : identification de l'a posteriori jointe.
On reconnaît :

$$p_t(x_0|x_t, y) = \frac{p(y|x_0)\, p_t(x_t|x_0)\, p(x_0)}{p_t(x_t|y)\, p(y)}$$

En divisant le numérateur et le dénominateur par $p_t(x_t|y)$:

$$\nabla_{x_t} \log p_t(x_t|y) = \frac{\nabla_{x_t} p_t(x_t|y)}{p_t(x_t|y)} = \int p_t(x_0|x_t, y) \cdot \frac{\sqrt{\bar{\alpha}_t}\, x_0 - x_t}{1 - \bar{\alpha}_t}\, \mathrm{d}x_0 = \frac{\sqrt{\bar{\alpha}_t}\, \mathbb{E}[X_0|x_t, y] - x_t}{1 - \bar{\alpha}_t}$$

■

Il reste donc à calculer $\mathbb{E}[X_0|X_t, Y]$ de manière explicite.

X.2 Étape 2 : loi de $X_0|X_t, Y$ sous les hypothèses ΠGDM

Proposition X.2.1— A posteriori jointe
Sous H1 et H2 :

$$p_t(x_0 \mid x_t, y) \;\propto\; p(y \mid x_0) \cdot p_t(x_0 \mid x_t) \tag{28}$$

Démonstration.
Étape 1 : Bayes. Par la règle de Bayes :

$$p_t(x_0 \mid x_t, y) = \frac{p(y \mid x_0, x_t)\, p_t(x_0 \mid x_t)}{p_t(y \mid x_t)}$$

Étape 2 : Markov. Par la chaîne $Y \leftarrow X_0 \rightarrow X_t$, on a $p(y \mid x_0, x_t) = p(y \mid x_0)$ (D1).
Étape 3 : conclusion. Le dénominateur $p_t(y \mid x_t)$ est indépendant de x_0, donc :

$$p_t(x_0 \mid x_t, y) \propto p(y \mid x_0) \cdot p_t(x_0 \mid x_t)$$

■

X.3 Étape 3 : produit de gaussiennes et complétion du carré

Sous nos hypothèses, les deux termes du produit sont gaussiens :

$$p(y \mid x_0) = \mathcal{N}(y;\; Ax_0,\; \sigma_b^2 I_m) \quad \text{(par H2)} \tag{29}$$

$$p_t(x_0 \mid x_t) = \mathcal{N}(x_0;\; \hat{x}_0(x_t),\; r_t^2 I_n) \quad \text{(par H1)} \tag{30}$$

Résultat X.3.1— A posteriori gaussienne en forme fermée

Sous H1 et H2, l'a posteriori $p_t(x_0 \mid x_t, y)$ est gaussienne :

$$X_0 \mid X_t, Y \sim \mathcal{N}(\mu_{\text{post}},\ \Sigma_{\text{post}}) \tag{31}$$

avec :

$$\boxed{\Sigma_{\text{post}} = \left(\frac{A^T A}{\sigma_b^2} + \frac{I_n}{r_t^2}\right)^{-1}} \tag{32}$$

$$\boxed{\mu_{\text{post}} = \Sigma_{\text{post}} \left(\frac{A^T y}{\sigma_b^2} + \frac{\hat{x}_0(x_t)}{r_t^2}\right)} \tag{33}$$

Démonstration.

Étape 1 : log-a posteriori. Par la Proposition X.2.1 et les hypothèses H1 et H2 :

$$\begin{aligned} \log p_t(x_0 \mid x_t, y) &= \log p(y \mid x_0) + \log p_t(x_0 \mid x_t) + \text{cte} \\ &= -\frac{\|y - Ax_0\|^2}{2\sigma_b^2} - \frac{\|x_0 - \hat{x}_0\|^2}{2r_t^2} + \text{cte} \end{aligned} \tag{34}$$

Étape 2 : développement et regroupement des termes en x_0.

$$= -\frac{1}{2}\left[x_0^T\left(\frac{A^T A}{\sigma_b^2} + \frac{I_n}{r_t^2}\right)x_0 - 2\,x_0^T\left(\frac{A^T y}{\sigma_b^2} + \frac{\hat{x}_0}{r_t^2}\right)\right] + \text{cte} \tag{35}$$

Étape 3 : identification. La forme quadratique $-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)$ se développe en $-\frac{1}{2}[x^T\Sigma^{-1}x - 2x^T\Sigma^{-1}\mu] + \text{cte}$. Par identification :

$$\Sigma_{\text{post}}^{-1} = \frac{A^T A}{\sigma_b^2} + \frac{I_n}{r_t^2}, \qquad \Sigma_{\text{post}}^{-1}\mu_{\text{post}} = \frac{A^T y}{\sigma_b^2} + \frac{\hat{x}_0}{r_t^2}$$

En multipliant à gauche par Σ_{post}, on obtient les expressions annoncées. ■

Remarque— Interprétation de μ_{post}

La moyenne a posteriori μ_{post} est un **compromis pondéré** entre deux sources d'information :

(i) le terme $\frac{A^T y}{\sigma_b^2}$, qui pousse vers la cohérence avec les mesures y, pondéré inversement par le bruit de mesure σ_b^2 ;

(ii) le terme $\frac{\hat{x}_0}{r_t^2}$, qui pousse vers la prédiction du denoiser, pondéré inversement par l'incertitude du denoiser r_t^2.

Quand $\sigma_b \to 0$ (mesures parfaites), $\mu_{\text{post}} \to A^\dagger y$; quand $r_t \to 0$ (denoiser parfait), $\mu_{\text{post}} \to \hat{x}_0$.

X.4 Résultat principal : score conditionnel explicite

En combinant la Proposition X.1.1 et le résultat X.3.1 :

Résultat X.4.1— Score conditionnel

Sous les hypothèses H1–H2 :

$$\boxed{\nabla_{x_t} \log p_t(x_t|y) = \frac{\sqrt{\bar{\alpha}_t}\, \mu_{\text{post}} - x_t}{1 - \bar{\alpha}_t}} \tag{36}$$

où :

$$\mu_{\text{post}} = \left(\frac{A^T A}{\sigma_b^2} + \frac{I_n}{r_t^2} \right)^{-1} \left(\frac{A^T y}{\sigma_b^2} + \frac{\hat{x}_0(x_t)}{r_t^2} \right)$$

et $\hat{x}_0(x_t) = \mathbb{E}[X_0|X_t = x_t]$ est le denoiser de Tweedie approché par s_θ.

Remarque— Lien avec DPS et ΠGDM classique

On retrouve les méthodes précédentes comme cas limites :

(i) $r_t^2 \to 0$: $\mu_{\text{post}} \to \hat{x}_0$, et on retrouve le score DPS.

(ii) ΠGDM classique (Résultat VII.6.1) calcule $\nabla_{x_t} \log p(y|x_t)$ séparément, puis l'ajoute au score inconditionnel. Ici, on obtient directement le score conditionnel total, ce qui évite les problèmes numériques liés à la somme de deux termes de grandeurs très différentes.

X.5 Vers l'optimisation variationnelle de r_t^2 et σ_b^2

Le Résultat X.4.1 fournit le score conditionnel en forme fermée, mais dépend de deux hyperparamètres fixés manuellement : r_t^2 (incertitude du denoiser) et σ_b^2 (bruit de mesure). L'idée est de les traiter comme des **variables latentes** et de les estimer automatiquement par inférence variationnelle bayésienne (VB).

XI Modèle hiérarchique bayésien

XI.1 Variables et structure

On reformule le problème en distinguant les quantités observées des quantités à inférer.

Définition XI.1.1— Variables du modèle

Observations : $\boldsymbol{y} = (x_t,\, y,\, \hat{x}_0(x_t),\, A)$.
Variables latentes : $\boldsymbol{w} = (x_0,\, \tau_r,\, \tau_b)$, où :

$$\tau_r = 1/r_t^2 \quad \text{(précision du denoiser)} \tag{37}$$
$$\tau_b = 1/\sigma_b^2 \quad \text{(précision du bruit de mesure)} \tag{38}$$

On paramétrise en précisions τ plutôt qu'en variances σ^2 car les lois conjuguées (Gamma) s'expriment naturellement en précision.

XI.2 Lois du modèle génératif

Hypothèses XI.2.1— Modèle hiérarchique VB + ΠGDM

$$x_t \mid x_0 \sim \mathcal{N}\big(\sqrt{\bar{\alpha}_t}\, x_0,\ (1-\bar{\alpha}_t)\, I_n\big) \tag{M1}$$
$$x_0 \mid \tau_r \sim \mathcal{N}\big(\hat{x}_0(x_t),\ \tau_r^{-1}\, I_n\big) \tag{M2}$$
$$y \mid x_0,\, \tau_b \sim \mathcal{N}\big(A\, x_0,\ \tau_b^{-1}\, I_m\big) \tag{M3}$$
$$\tau_r \sim \mathrm{Gamma}(a_0,\, b_0) \tag{M4}$$
$$\tau_b \sim \mathrm{Gamma}(c_0,\, d_0) \tag{M5}$$

Les équations M1–M3 reprennent exactement les hypothèses de la partie précédente (SDE forward, ΠGDM, problème inverse linéaire), et M4–M5 ajoutent des a prioris conjugués sur les précisions.

Remarque— Indépendances conditionnelles

La structure du modèle implique :

(i) $\tau_r \perp\!\!\!\perp \tau_b$ (a prioris indépendants)
(ii) $x_t \perp\!\!\!\perp y \mid x_0$ (chaîne de Markov $x_t \leftarrow x_0 \rightarrow y$)
(iii) $x_t \perp\!\!\!\perp \tau_b \mid x_0$ (le forward ne dépend pas du bruit de mesure)
(iv) $y \perp\!\!\!\perp \tau_r \mid x_0$ (les mesures ne dépendent pas de l'incertitude du denoiser)

XI.3 Loi jointe

Proposition XI.3.1— Factorisation de la loi jointe

$$\boxed{p_t(\boldsymbol{w}, \boldsymbol{y}) = p_t(x_t \mid x_0) \cdot p(y \mid x_0, \tau_b) \cdot p(x_0 \mid \tau_r) \cdot p(\tau_r) \cdot p(\tau_b)} \tag{39}$$

Démonstration.

Par la règle de la chaîne et les indépendances conditionnelles :

$$\begin{aligned} p_t(x_0, x_t, y, \tau_r, \tau_b) &= p_t(x_t \mid x_0, y, \tau_r, \tau_b) \cdot p(y \mid x_0, \tau_r, \tau_b) \cdot p(x_0 \mid \tau_r, \tau_b) \cdot p(\tau_r, \tau_b) \\ &= p_t(x_t \mid x_0) \cdot p(y \mid x_0, \tau_b) \cdot p(x_0 \mid \tau_r) \cdot p(\tau_r) \cdot p(\tau_b) \end{aligned} \tag{40}$$

où l'on a utilisé : $x_t \perp\!\!\!\perp (y, \tau_r, \tau_b) \mid x_0$, puis $y \perp\!\!\!\perp \tau_r \mid x_0$, puis $x_0 \perp\!\!\!\perp \tau_b \mid \tau_r$, et enfin $\tau_r \perp\!\!\!\perp \tau_b$. ■

XI.4 Log-vraisemblance jointe

On calcule $\log p_t(\boldsymbol{w}, \boldsymbol{y})$ terme par terme.

Proposition XI.4.1— Termes de la log-jointe

En ne gardant que les termes qui dépendent de $\boldsymbol{w} = (x_0, \tau_r, \tau_b)$:

Terme 1 : par M1, $x_t \mid x_0 \sim \mathcal{N}(\sqrt{\bar{\alpha}_t}\, x_0,\ (1 - \bar{\alpha}_t)\, I_n)$:

$$\log p_t(x_t \mid x_0) = -\frac{1}{2(1 - \bar{\alpha}_t)} \|x_t - \sqrt{\bar{\alpha}_t}\, x_0\|^2 + \text{cte} \tag{41}$$

Terme 2 : par M3, $y \mid x_0, \tau_b \sim \mathcal{N}(A x_0,\ \tau_b^{-1} I_m)$:

$$\log p(y \mid x_0, \tau_b) = \frac{m}{2} \log \tau_b - \frac{\tau_b}{2} \|y - A x_0\|^2 + \text{cte} \tag{42}$$

Terme 3 : par M2, $x_0 \mid \tau_r \sim \mathcal{N}(\hat{x}_0,\ \tau_r^{-1} I_n)$:

$$\log p(x_0 \mid \tau_r) = \frac{n}{2} \log \tau_r - \frac{\tau_r}{2} \|x_0 - \hat{x}_0\|^2 + \text{cte} \tag{43}$$

Terme 4 : par M4, $\tau_r \sim \text{Gamma}(a_0, b_0)$:

$$\log p(\tau_r) = (a_0 - 1) \log \tau_r - b_0\, \tau_r + \text{cte} \tag{44}$$

Terme 5 : par M5, $\tau_b \sim \text{Gamma}(c_0, d_0)$:

$$\log p(\tau_b) = (c_0 - 1) \log \tau_b - d_0\, \tau_b + \text{cte} \tag{45}$$

Démonstration.

Chaque terme s'obtient en développant la log-densité correspondante et en absorbant dans cte tout ce qui ne dépend pas de (x_0, τ_r, τ_b).

Pour le terme 1 : $\log \mathcal{N}(x_t;\, \mu, \sigma^2 I) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|x_t - \mu\|^2$. Le premier terme est indépendant de x_0, d'où le résultat.

Pour les termes 2 et 3 : même développement, mais la précision $\tau = 1/\sigma^2$ apparaît comme facteur multiplicatif devant la norme et comme $\frac{n}{2}\log\tau$.

Pour les termes 4 et 5 : la densité Gamma(α, β) est $p(\tau) \propto \tau^{\alpha-1}e^{-\beta\tau}$, d'où $\log p(\tau) = (\alpha - 1)\log\tau - \beta\tau + \text{cte}$. ■

En sommant les cinq termes :

Résultat XI.4.1— Log-vraisemblance jointe

$$\boxed{\begin{aligned}\log p_t(\boldsymbol{w}, \boldsymbol{y}) \;=\; & -\frac{1}{2(1-\bar{\alpha}_t)}\|x_t - \sqrt{\bar{\alpha}_t}\, x_0\|^2 \\ & + \left(\frac{m}{2} + c_0 - 1\right)\log\tau_b - \left(d_0 + \tfrac{1}{2}\|y - Ax_0\|^2\right)\tau_b \\ & + \left(\frac{n}{2} + a_0 - 1\right)\log\tau_r - \left(b_0 + \tfrac{1}{2}\|x_0 - \hat{x}_0\|^2\right)\tau_r \\ & + \text{cte}\end{aligned}} \tag{46}$$

XII Approximation variationnelle

XII.1 Pourquoi approcher l'a posteriori ?

On dispose de la loi jointe $p_t(\boldsymbol{w}, \boldsymbol{y})$ (Résultat XI.4.1), mais l'objectif est d'échantillonner selon l'a posteriori $p_t(\boldsymbol{w}|\boldsymbol{y})$. Or, par la règle de Bayes :

$$p_t(\boldsymbol{w}|\boldsymbol{y}) = \frac{p_t(\boldsymbol{w}, \boldsymbol{y})}{p_t(\boldsymbol{y})}, \qquad \text{où} \quad p_t(\boldsymbol{y}) = \int p_t(\boldsymbol{w}, \boldsymbol{y})\,\mathrm{d}\boldsymbol{w}$$

L'intégrale de normalisation $p_t(\boldsymbol{y})$ porte sur toutes les variables latentes $\boldsymbol{w} = (x_0, \tau_r, \tau_b)$ en dimension $n + 2$. En imagerie, $n \approx 200\,000$: cette intégrale est intractable. Connaître la jointe ne suffit donc pas, il faut approcher l'a posteriori.

XII.2 Choix de la mesure de dissemblance

On cherche une densité approchante $q(\boldsymbol{w})$ la plus proche possible de $p_t(\boldsymbol{w}|\boldsymbol{y})$. La "proximité" se mesure par une mesure de dissemblance $\Delta(q\|p_t(\cdot|\boldsymbol{y}))$. Un choix naturel est la divergence de Kullback-Leibler $\mathcal{KL}$, qui mesure la différence entre deux densités de probabilité :

$$\mathcal{KL}[q\|p_t(\cdot|\boldsymbol{y})] = \int_{\mathbb{R}^{n+2}} q(\boldsymbol{w})\log\frac{q(\boldsymbol{w})}{p_t(\boldsymbol{w}|\boldsymbol{y})}\,\mathrm{d}\boldsymbol{w} \tag{47}$$

Cette divergence possède les propriétés suivantes :

— $\mathcal{KL}[q\|p] \geq 0$ pour tout q, p, avec égalité si et seulement si $q = p$ presque partout ;

— elle est **asymétrique** : $\mathcal{KL}[q\|p] \neq \mathcal{KL}[p\|q]$ en général ;

— elle est convexe.

En raison de l'asymétrie de $\mathcal{KL}$, deux possibilités existent selon l'ordre des arguments :

(i) **Divergence** $\mathcal{KL}_{RM}$: $\mathcal{KL}[p_t(\cdot|\boldsymbol{y})\|q]$. Cette divergence est optimale d'un point de vue bayésien car sa minimisation donne une approximation de risque minimale. Cependant, elle est inutilisable en pratique car elle nécessite de connaître les lois marginales $p_t(w_j|\boldsymbol{y})$.

(ii) **Divergence** $\mathcal{KL}_{BV}$: $\mathcal{KL}[q\|p_t(\cdot|\boldsymbol{y})]$. Les méthodes d'approximation bayésienne variationnelle utilisent cette divergence car elle permet d'obtenir des solutions analytiques, comme on le verra dans la suite.

En pratique, $\mathcal{KL}_{BV}$ n'est pas directement calculable car elle dépend de $p_t(\boldsymbol{w}|\boldsymbol{y})$, que l'on ne connaît pas (la fonction de partition $p_t(\boldsymbol{y}) = \int p_t(\boldsymbol{w}, \boldsymbol{y})\,\mathrm{d}\boldsymbol{w}$ est intractable). On développe donc :

$$\begin{aligned}\mathcal{KL}_{BV} &= \int q(\boldsymbol{w}) \log \frac{q(\boldsymbol{w})}{p_t(\boldsymbol{w}|\boldsymbol{y})}\,\mathrm{d}\boldsymbol{w} = \int q(\boldsymbol{w}) \log \frac{q(\boldsymbol{w})\,p_t(\boldsymbol{y})}{p_t(\boldsymbol{w}, \boldsymbol{y})}\,\mathrm{d}\boldsymbol{w} \\ &= \log p_t(\boldsymbol{y}) - \underbrace{\int q(\boldsymbol{w}) \log \frac{p_t(\boldsymbol{w}, \boldsymbol{y})}{q(\boldsymbol{w})}\,\mathrm{d}\boldsymbol{w}}_{=:\mathcal{F}(q)} \end{aligned} \tag{48}$$

La quantité $\mathcal{F}(q) = \mathbb{E}_q\left[\log \frac{p_t(\boldsymbol{w},\boldsymbol{y})}{q(\boldsymbol{w})}\right]$ est l'**énergie libre négative**. Elle ne dépend que de la loi jointe $p_t(\boldsymbol{w}, \boldsymbol{y})$, que l'on connaît explicitement (Résultat XI.4.1). Comme $\mathcal{KL}_{BV} \geq 0$, on a $\mathcal{F}(q) \leq \log p_t(\boldsymbol{y})$: l'énergie libre est une borne inférieure de la log-évidence.

Résultat XII.2.1— Objectif variationnel

$$\boxed{\min_q \mathcal{KL}_{BV} \iff \max_q \mathcal{F}(q)} \tag{49}$$

Avec :

$$\mathcal{F}(q) = \int q(\boldsymbol{w}) \log \frac{p_t(\boldsymbol{w}, \boldsymbol{y})}{q(\boldsymbol{w})}\,\mathrm{d}\boldsymbol{w} = \mathbb{E}_q\left[\log \frac{p_t(\boldsymbol{w}, \boldsymbol{y})}{q(\boldsymbol{w})}\right] \tag{50}$$

Remarque— Interprétation

À convergence de l'algorithme BV, $\mathcal{KL}_{BV} \approx 0$ et donc $\mathcal{F}(q) \approx \ln p_t(\boldsymbol{y})$. L'énergie libre peut ainsi servir d'approximation de la log-évidence pour la sélection de modèle.

XII.3 Hypothèse de champ moyen

Hypothèses XII.3.1— Factorisation champ moyen

On suppose que la densité approchante factorise :

$$q(\boldsymbol{w}) = \left(\prod_{i=1}^{n} q_i(x_{0,i})\right) \cdot q(\tau_r)\, q(\tau_b) \tag{MF}$$

où $x_{0,i}$ désigne la i-ème composante de $x_0 \in \mathbb{R}^n$.

Cette hypothèse rend toutes les variables latentes mutuellement indépendantes sous q : chaque pixel $x_{0,i}$ est indépendant des autres et des précisions τ_r, τ_b. C'est l'hypothèse la plus fine du cadre champ moyen, qui permettra d'obtenir des mises à jour analytiques pour chaque facteur.

Hypothèses XII.3.2— Forme paramétrique de $q(x_0)$

On choisit une famille gaussienne pour chaque composante :

$$q_i(x_{0,i}) = \mathcal{N}(x_{0,i} \mid \mu_i,\, \Sigma_i), \quad i = 1, \dots, n \tag{51}$$

où $(\mu_i, \Sigma_i)_{i=1,\dots,n}$ sont les paramètres variationnels à optimiser.

Rappel— Lois des précisions (Hypothèses XI.2.1)

Les a priori conjugués sur les précisions induisent des lois approchantes de même famille :

$$q(\tau_r) = \mathrm{Gamma}(\tau_r \mid a_0,\, b_0) \tag{52}$$

$$q(\tau_b) = \mathrm{Gamma}(\tau_b \mid c_0,\, d_0) \tag{53}$$

Remarque— Notation vectorielle

On note $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)^T \in \mathbb{R}^n$ et $\boldsymbol{\Sigma} = (\Sigma_1, \dots, \Sigma_n)^T \in \mathbb{R}^n$ les vecteurs des moyennes et variances marginales. Attention : Σ_i est un **scalaire** (la variance du pixel i), pas une matrice. L'hypothèse champ moyen force la matrice de covariance de $q(x_0)$ à être diagonale : $\mathrm{Cov}_q(x_0) = \mathrm{diag}(\Sigma_1, \dots, \Sigma_n)$.

XIII Optimisation dans l'espace des mesures

La section précédente a réduit le problème à la maximisation de $\mathcal{F}(q) = \mathbb{E}_q[\log p_t(\boldsymbol{w}, \boldsymbol{y})]$ sur un espace de densités séparables. Nous présentons maintenant l'algorithme d'optimisation, adapté de Zheng, Fraysse et Rodet [2].

XIII.1 Pourquoi ne pas faire de la descente de gradient classique ?

En optimisation vectorielle classique, on dispose d'un vecteur $x^k \in \mathbb{R}^d$ et on le met à jour par :

$$x^{k+1} = x^k + \alpha\, \nabla F(x^k)$$

Ici, l'inconnue n'est pas un vecteur mais une fonction $q \in \Omega$, où Ω est un espace de dimension infinie. On ne peut pas transposer naïvement la descente de gradient pour trois raisons :

(i) **positivité** : $q^k + \alpha\, \delta q$ peut devenir négatif, et une densité de probabilité doit être positive ;

(ii) **normalisation** : $\int (q^k + \alpha\, \delta q)\, \mathrm{d}\boldsymbol{w}$ n'a aucune raison de valoir 1 ;

(iii) **structure** : l'espace des densités n'est pas un espace de Hilbert (pas de produit scalaire canonique), c'est un espace de Banach. Le gradient au sens de Hilbert n'est donc pas directement défini.

La solution, introduite par Zheng, Fraysse et Rodet [2], est de reformuler le problème dans l'espace des mesures de probabilité, où la mise à jour sera multiplicative (et non additive), ce qui garantit automatiquement positivité et normalisation.

XIII.2 Espaces fonctionnels

Définition XIII.2.1— Espace des densités séparables Ω

$$\Omega = \left\{ q : \mathbb{R}^{n+2} \to \mathbb{R}_+ \;\middle|\; q \text{ est une densité de probabilité et } q(\boldsymbol{w}) = \prod_{i=1}^{n} q_i(x_{0,i}) \cdot q(\tau_r) \cdot q(\tau_b) \right\} \tag{54}$$

L'énergie libre variationnelle (Résultat XII.2.1) est la fonctionnelle :

$$\mathcal{F} : \Omega \to \mathbb{R}, \qquad \mathcal{F}(q) = \mathbb{E}_q[\log p_t(\boldsymbol{w}, \boldsymbol{y})]$$

Définition XIII.2.2— Espace des mesures de probabilité $\mathcal{A}$

$$\mathcal{A} = \bigotimes_{i=1}^{n} \mathcal{A}_i \;\otimes\; \mathcal{A}_{\tau_r} \;\otimes\; \mathcal{A}_{\tau_b} \tag{55}$$

où chaque $\mathcal{A}_j = \{\mu_j : \text{mesure de probabilité},\ \mu_j(\mathrm{d}w_j) = q_j(w_j)\, \mathrm{d}w_j \text{ avec } q_j \text{ densité}\}$.
L'espace $\mathcal{A}$ est le produit cartésien des espaces de mesures de probabilité marginales.

Proposition XIII.2.1— Équivalence des problèmes d'optimisation

Si $\mu \in \mathcal{A}$ a pour densité $q \in \Omega$, c'est-à-dire $\mu(\mathrm{d}\boldsymbol{w}) = q(\boldsymbol{w})\, \mathrm{d}\boldsymbol{w}$, alors on définit :

$$F : \mathcal{A} \to \mathbb{R}, \qquad F(\mu) = \mathcal{F}(q)$$

et les deux problèmes d'optimisation sont équivalents :

$$\boxed{q^{\text{opt}} = \arg\max_{q \in \Omega} \mathcal{F}(q) \quad \Longleftrightarrow \quad \mu^{\text{opt}} = \arg\max_{\mu \in \mathcal{A}} F(\mu)} \tag{56}$$

Démonstration.

La correspondance $q \mapsto \mu$ définie par $\mu(\mathrm{d}\boldsymbol{w}) = q(\boldsymbol{w})\,\mathrm{d}\boldsymbol{w}$ est une bijection entre Ω (densités séparables) et $\mathcal{A}$ (mesures de probabilité à densité séparable). Par construction, $F(\mu) = \mathcal{F}(q)$. Donc q^* maximise $\mathcal{F}$ sur Ω si et seulement si la mesure μ^* associée maximise F sur $\mathcal{A}$. ■

L'intérêt de travailler dans $\mathcal{A}$ plutôt que dans Ω est que l'on dispose d'outils de calcul différentiel adaptés (différentielle de Gâteaux) et que la mise à jour multiplicative via le théorème de Radon-Nikodym garantira les contraintes de positivité et de normalisation.

XIII.3 Différentielle de Gâteaux de l'énergie libre

Dans un espace de Hilbert de dimension finie, la direction de montée est donnée par le gradient ∇F. Dans l'espace fonctionnel Ω (espace de Banach, sans produit scalaire), on utilise à la place la différentielle de Gâteaux, qui généralise la notion de dérivée directionnelle.

Définition XIII.3.1— Différentielle de Gâteaux

La différentielle de Gâteaux de $\mathcal{F}$ en $q \in \Omega$ dans la direction $\tilde{q} \in \Omega$ est la fonctionnelle linéaire :

$$\mathrm{d}\mathcal{F}_q(\tilde{q}) = \int_{\mathbb{R}^{n+2}} \mathrm{d}f(q, \boldsymbol{w})\,\tilde{q}(\boldsymbol{w})\,\mathrm{d}\boldsymbol{w} \tag{57}$$

où $\mathrm{d}f(q, \boldsymbol{w})$ est le **noyau** de la différentielle, qui joue le rôle du gradient si j'ai bien compris ?

Proposition XIII.3.1— Noyau de la différentielle — cas séparable

Pour $q \in \Omega$ séparable, le noyau se décompose en une somme de contributions marginales :

$$\mathrm{d}f(q, \boldsymbol{w}) = \sum_j \mathrm{d}_j f(q, w_j) \tag{58}$$

où la somme porte sur toutes les composantes $w_j \in \{x_{0,1}, \ldots, x_{0,n}, \tau_r, \tau_b\}$, et chaque terme vaut :

$$\boxed{\mathrm{d}_j f(q, w_j) = \langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{\prod_{l \neq j} q_l(w_l)} - \log q_j(w_j) - 1} \tag{59}$$

Avec : $\langle \cdot \rangle_q =: \mathbb{E}_q[\cdot]$

Démonstration.

Étape 1 : définition de l'énergie libre. Par le Résultat XII.2.1 :

$$\mathcal{F}(q) = \mathbb{E}_q[\log p_t(\boldsymbol{w}, \boldsymbol{y})] = \int q(\boldsymbol{w}) \log p_t(\boldsymbol{w}, \boldsymbol{y})\,\mathrm{d}\boldsymbol{w}$$

On cherche la dérivée directionnelle. Considérons une perturbation $q_\varepsilon = q + \varepsilon(\tilde{q} - q)$ pour $\varepsilon > 0$ petit. On a :

$$\mathcal{F}(q_\varepsilon) = \int q_\varepsilon(\boldsymbol{w}) \log p_t(\boldsymbol{w}, \boldsymbol{y})\,\mathrm{d}\boldsymbol{w}$$

Étape 2 : cas d'une perturbation sur la composante j seule. Supposons que seule la composante q_j est perturbée en $q_j + \varepsilon(\tilde{q}_j - q_j)$, les autres restant fixées. On note $q_\varepsilon(\boldsymbol{w}) =$

$(q_j + \varepsilon(\tilde{q}_j - q_j)) \prod_{l \neq j} q_l$. Alors :

$$\begin{aligned}\mathcal{F}(q_\varepsilon) &= \int (q_j(w_j) + \varepsilon(\tilde{q}_j(w_j) - q_j(w_j))) \prod_{l \neq j} q_l(w_l) \cdot \log p_t(\boldsymbol{w}, \boldsymbol{y}) \, \mathrm{d}\boldsymbol{w} \\ &= \mathcal{F}(q) + \varepsilon \int (\tilde{q}_j - q_j)(w_j) \underbrace{\left[\int \prod_{l \neq j} q_l(w_l) \cdot \log p_t(\boldsymbol{w}, \boldsymbol{y}) \prod_{l \neq j} \mathrm{d}w_l \right]}_{= \langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{\prod_{l \neq j} q_l}} \mathrm{d}w_j + O(\varepsilon) \qquad (60)\end{aligned}$$

Étape 3 : terme entropique. L'énergie libre complète inclut aussi le terme d'entropie $-\mathbb{E}_q[\log q(\boldsymbol{w})]$. Pour q séparable, $\log q(\boldsymbol{w}) = \sum_l \log q_l(w_l)$. La perturbation sur q_j donne :

$$\begin{aligned}-\mathbb{E}_{q_\varepsilon}[\log q_\varepsilon] &= -\int q_\varepsilon \log q_\varepsilon \, \mathrm{d}\boldsymbol{w} \\ &= -\mathbb{E}_q[\log q] - \varepsilon \int (\tilde{q}_j - q_j)(w_j)(\log q_j(w_j) + 1) \, \mathrm{d}w_j + O(\varepsilon) \qquad (61)\end{aligned}$$

Étape 4 : combinaison. En sommant les deux contributions :

$$\left. \frac{\mathrm{d}}{\mathrm{d}\varepsilon} \right|_{\varepsilon=0} \mathcal{F}(q_\varepsilon) = \int (\tilde{q}_j - q_j)(w_j) \left[\langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{\prod_{l \neq j} q_l} - \log q_j(w_j) - 1 \right] \mathrm{d}w_j$$

On identifie donc $\mathrm{d}_j f(q, w_j) = \langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{\prod_{l \neq j} q_l} - \log q_j(w_j) - 1$.

Étape 5 : somme sur les composantes. Par linéarité de la dérivée directionnelle, pour une perturbation générale de toutes les composantes, le noyau total est $\mathrm{d}f(q, \boldsymbol{w}) = \sum_j \mathrm{d}_j f(q, w_j)$. ■

Remarque— Lien avec CAVI

Si l'on pose $\mathrm{d}_j f(q, w_j) = 0$ pour tout j (condition d'optimalité de premier ordre), on obtient :

$$\log q_j^*(w_j) = \langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{\prod_{l \neq j} q_l} - 1$$

soit, après renormalisation :

$$q_j^*(w_j) = K_j \exp\left[\langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{\prod_{l \neq j} q_l} \right] \qquad (62)$$

C'est exactement la solution de CAVI (*Coordinate Ascent Variational Inference*), la méthode classique de BV. CAVI résout ce système par Gauss-Seidel : on fixe tous les q_l pour $l \neq j$, on met à jour q_j, puis on passe à la composante suivante. En imagerie, cela revient à mettre à jour **pixel par pixel** ($n \approx 200\,000$ composantes), ce qui est extrêmement lent.

XIII.4 Mise à jour multiplicative par Radon-Nikodym

On veut faire mieux que CAVI en mettant à jour toutes les composantes simultanément, par une descente de gradient. Mais comme souligné plus haut, l'addition $q^{k+1} = q^k + \alpha \, \delta q$ ne respecte ni la positivité ni la normalisation. On passe donc dans l'espace des mesures $\mathcal{A}$.

Théorème XIII.4.1— Radon-Nikodym — mise à jour dans $\mathcal{A}$ (admis [?])

Soit $\mu^k \in \mathcal{A}$ une mesure de probabilité de Radon de densité q^k. Toute mesure μ^{k+1} absolument continue par rapport à μ^k s'écrit :

$$\mu^{k+1}(\mathrm{d}\boldsymbol{w}) = h^k(\boldsymbol{w})\,\mu^k(\mathrm{d}\boldsymbol{w}) \tag{63}$$

où $h^k \in L^1(\mu^k)$ est une fonction positive (la dérivée de Radon-Nikodym). En termes de densités :

$$\boxed{q^{k+1}(\boldsymbol{w}) = h^k(\boldsymbol{w})\,q^k(\boldsymbol{w})} \tag{64}$$

La mise à jour est donc multiplicative : on multiplie la densité courante q^k par un facteur $h^k > 0$. Cela garantit automatiquement $q^{k+1} > 0$. La normalisation $\int q^{k+1} = 1$ est assurée par une constante multiplicative dans h^k.

Remarque— Choix exponentiel pour h^k

La fonctionnelle $\mathcal{F}$ contient le terme entropique $-\mathbb{E}_q[\log q]$, qui est non-linéaire en q. Une mise à jour multiplicative $q^{k+1} \propto q^k \cdot e^d$ rend ce terme linéaire en la direction d (car $\log(q^k e^d) = \log q^k + d$), ce qui permet une optimisation du pas en forme fermée. On pose donc :

$$h^k(\boldsymbol{w}) = K^k(s)\,\exp\big[\boldsymbol{D}^k(\boldsymbol{w}) \cdot s\big] \tag{65}$$

où $\boldsymbol{D}^k(\boldsymbol{w}) = [d_1^k(\boldsymbol{w}), \ldots, d_I^k(\boldsymbol{w})]$ est un ensemble de I directions fonctionnelles, $s = [s_1, \ldots, s_I]^T$ le vecteur de pas, et $K^k(s)$ la constante de normalisation :

$$K^k(s) = \left(\int \exp\big[\boldsymbol{D}^k(\boldsymbol{w}) \cdot s\big]\,q^k(\boldsymbol{w})\,\mathrm{d}\boldsymbol{w}\right)^{-1}$$

Ce choix : (i) garantit $h^k > 0$ (car exponentiel), (ii) assure $\int q^{k+1} = 1$, (iii) linéarise l'entropie dans la direction d.

En combinant (64) et (65) :

Résultat XIII.4.2— Règle de mise à jour EMG-VBA dans l'espace Ω (Bayésian Variational Memory Gradient : mémoire de la direction précédente)

$$\boxed{q^{k+1}(\boldsymbol{w}) = K^k(s)\,q^k(\boldsymbol{w})\,\exp\big[\boldsymbol{D}^k(\boldsymbol{w})\,s\big]} \tag{66}$$

XIII.5 Sous-espace de directions : gradient à mémoire

Il reste à choisir les directions $\boldsymbol{D}^k$. Par analogie avec l'optimisation par sous-espace en dimension finie, où l'on utilise $D^k = [-\nabla F(x^k),\, d^{k-1}]$ (direction de gradient + mémoire de la direction précédente), Zheng, Fraysse et Rodet [2] proposent le sous-espace de dimension $I = 2$:

Définition XIII.5.1— Sous-espace Memory Gradient (MG)

$$\boldsymbol{D}^k_{\mathrm{MG}}(\boldsymbol{w}) = \left[\mathrm{d}f(q^k, \boldsymbol{w}),\ \ d^{k-1}(\boldsymbol{w})\right] \tag{67}$$

où :

(i) $\mathrm{d}f(q^k, \boldsymbol{w}) = \sum_j \mathrm{d}_j f(q^k, w_j)$ est le noyau de la différentielle de Gâteaux (Proposition XIII.3.1), qui joue le rôle du gradient je pense ;

(ii) $d^{k-1}(\boldsymbol{w}) = \log\left(\frac{q^k(\boldsymbol{w})}{q^{k-1}(\boldsymbol{w})}\right) = \sum_j \log\left(\frac{q^k_j(w_j)}{q^{k-1}_j(w_j)}\right)$ est la direction précédente, qui apporte la "mémoire".

En injectant le sous-espace MG dans la règle de mise à jour (66) :

Proposition XIII.5.1— Mise à jour explicite EMG-VBA

Chaque facteur q^{k+1}_j se met à jour selon :

$$q^{k+1}_j(w_j) = K^k_j(s)\, q^k_j(w_j) \cdot \left(\frac{q^r_j(w_j)}{q^k_j(w_j)}\right)^{s_1} \cdot \left(\frac{q^k_j(w_j)}{q^{k-1}_j(w_j)}\right)^{s_2} \tag{68}$$

où q^r_j est la distribution de référence :

$$q^r_j(w_j) \propto \exp\left[\langle \log p_t(\boldsymbol{w}, \boldsymbol{y})\rangle_{\prod_{l\neq j} q^k_l}\right] \tag{69}$$

Démonstration.

Étape 1 : injection des directions. Par le Résultat XIII.4.2 et la Définition XIII.5.1 :

$$q^{k+1}(\boldsymbol{w}) = K^k(s)\, q^k(\boldsymbol{w})\, \exp\left[s_1\, \mathrm{d}f(q^k, \boldsymbol{w}) + s_2\, d^{k-1}(\boldsymbol{w})\right]$$

Comme q est séparable, cela se factorise composante par composante :

$$q^{k+1}_j(w_j) = K^k_j(s)\, q^k_j(w_j)\, \exp\left[s_1\, \mathrm{d}_j f(q^k, w_j) + s_2\, \log \frac{q^k_j(w_j)}{q^{k-1}_j(w_j)}\right]$$

Étape 2 : substitution du noyau de Gâteaux. Par (59) :

$$\mathrm{d}_j f(q^k, w_j) = \langle \log p_t(\boldsymbol{w}, \boldsymbol{y})\rangle_{\prod_{l\neq j} q^k_l} - \log q^k_j(w_j) - 1$$

Donc :

$$\exp[s_1\, \mathrm{d}_j f] = \exp\left[s_1\left(\langle \log p_t\rangle_{\prod_{l\neq j} q^k_l} - \log q^k_j - 1\right)\right] = \left(\frac{q^r_j(w_j)}{q^k_j(w_j)}\right)^{s_1} \cdot e^{-s_1}$$

où $q^r_j(w_j) \propto \exp[\langle \log p_t\rangle_{\prod_{l\neq j} q^k_l}]$ est exactement la solution CAVI pour la composante j.

Étape 3 : terme de mémoire.

$$\exp\left[s_2\, \log \frac{q^k_j}{q^{k-1}_j}\right] = \left(\frac{q^k_j(w_j)}{q^{k-1}_j(w_j)}\right)^{s_2}$$

Étape 4 : combinaison. En absorbant e^{-s_1} dans la constante de normalisation $K_j^k(s)$, on obtient (68). ■

XIII.6 Choix du pas

Le pas optimal $s^* = (s_1^*, s_2^*)$ est celui qui maximise l'énergie libre le long du sous-espace :

Définition XIII.6.1— Recherche de pas

$$s^* = \arg\max_{s \in \mathbb{R}^2} \; g^k(s) := \mathcal{F}\big(K^k(s)\, q^k \, \exp\big[\boldsymbol{D}_{\mathrm{MG}}^k \, s\big]\big) \tag{70}$$

En pratique, le calcul exact de s^* est coûteux. On utilise un pas sous-optimal par développement de Taylor à l'ordre 2 de g^k autour de $s = 0$:

$$\tilde{g}^k(s) = g^k(0) + \left(\frac{\partial g^k}{\partial s}\bigg|_{s=0}\right)^T s + \frac{1}{2}\, s^T \left(\frac{\partial^2 g^k}{\partial s \partial s^T}\bigg|_{s=0}\right) s \tag{71}$$

Le maximum de cette approximation quadratique donne :

Résultat XIII.6.1— Pas sous-optimal

$$\boxed{\hat{s}_{\mathrm{subopt}} = -\left(\frac{\partial^2 g^k}{\partial s \partial s^T}\bigg|_{s=0}\right)^{-1} \frac{\partial g^k}{\partial s}\bigg|_{s=0}} \tag{72}$$

XIII.7 Synthèse de l'algorithme

L'algorithme complet alterne les mises à jour suivantes à chaque itération k :

1. **Calcul de** q_j^r : pour chaque composante $w_j \in \{x_{0,1}, \ldots, x_{0,n}, \tau_r, \tau_b\}$, calculer la distribution de référence (69) en moyennant $\log p_t(\boldsymbol{w}, \boldsymbol{y})$ sur toutes les autres composantes.
2. **Pas sous-optimal** : calculer $\hat{s}_{\mathrm{subopt}}$ par (72).
3. **Mise à jour** : appliquer (68) pour obtenir q_j^{k+1} pour tout j.

La section suivante explicite les calculs de q_j^r (et donc de $\mathrm{d}_j f$) pour chacune des trois familles de variables latentes : les composantes $x_{0,i}$, la précision τ_r et la précision τ_b.

XIII.8 Application à notre cas d'étude

Nous appliquons maintenant l'algorithme EMG-VBA au modèle hiérarchique défini par les Hypothèses XI.2.1 et 51. L'objectif est de calculer explicitement :

(i) les distributions de référence q_j^r pour chaque variable latente $w_j \in \{x_{0,1}, \ldots, x_{0,n}, \tau_r, \tau_b\}$;

(ii) les mises à jour EMG-VBA correspondantes ;

(iii) le pas sous-optimal $\hat{s}_{\mathrm{subopt}}$.

XIII.8.1 Rappel de la log-jointe

Par le Résultat XI.4.1, en ne gardant que les termes dépendant de $\boldsymbol{w} = (x_0, \tau_r, \tau_b)$:

$$\log p_t(\boldsymbol{w}, \boldsymbol{y}) = \underbrace{-\frac{\|x_t - \sqrt{\bar{\alpha}_t}\, x_0\|^2}{2(1-\bar{\alpha}_t)}}_{\text{(T1) : forward}} + \underbrace{\frac{m}{2}\log\tau_b - \frac{\tau_b}{2}\|y - Ax_0\|^2}_{\text{(T2) : mesure}} + \underbrace{\frac{n}{2}\log\tau_r - \frac{\tau_r}{2}\|x_0 - \hat{x}_0\|^2}_{\text{(T3) : a priori}} \tag{73}$$
$$+ \underbrace{(a_0 - 1)\log\tau_r - b_0\tau_r}_{\text{(T4)}} + \underbrace{(c_0 - 1)\log\tau_b - d_0\tau_b}_{\text{(T5)}}$$

XIII.8.2 Distribution de référence pour τ_b

Proposition XIII.8.1— Distribution de référence $q^r_{\tau_b}$

Sous l'hypothèse de champ moyen (MF), la distribution de référence pour τ_b est :

$$\boxed{q^r_{\tau_b}(\tau_b) = \text{Gamma}(\tau_b \mid \tilde{a}_b, \tilde{b}_b)} \tag{74}$$

avec :

$$\tilde{a}_b = \frac{m}{2} + c_0 \tag{75}$$

$$\tilde{b}_b = d_0 + \frac{1}{2}\left\langle \|y - Ax_0\|^2 \right\rangle_{q(x_0)} = d_0 + \frac{1}{2}\Big(\|y - A\boldsymbol{\mu}\|^2 + \text{tr}\big(\text{diag}(A^T A)\cdot\boldsymbol{\Sigma}\big)\Big) \tag{76}$$

Démonstration.

Étape 1 : identification des termes pertinents. Par la définition (69), on a :

$$\log q^r_{\tau_b}(\tau_b) = \langle \log p_t(\boldsymbol{w}, \boldsymbol{y}) \rangle_{q(x_0)\, q(\tau_r)} + \text{cte}$$

Dans l'expression (73), seuls les termes (T2) et (T5) dépendent de τ_b. Les termes (T1), (T3), (T4) ne contiennent pas τ_b et disparaissent dans la moyenne.

Étape 2 : moyenne sur x_0 et τ_r. Les termes (T2) et (T5) ne dépendent pas de τ_r, donc la moyenne sur $q(\tau_r)$ est triviale :

$$\begin{aligned}\log q^r_{\tau_b}(\tau_b) &= \left\langle \frac{m}{2}\log\tau_b - \frac{\tau_b}{2}\|y - Ax_0\|^2 + (c_0 - 1)\log\tau_b - d_0\tau_b \right\rangle_{q(x_0)} + \text{cte} \\ &= \left(\frac{m}{2} + c_0 - 1\right)\log\tau_b - \tau_b\left(d_0 + \frac{1}{2}\left\langle \|y - Ax_0\|^2 \right\rangle_{q(x_0)}\right) + \text{cte}\end{aligned} \tag{77}$$

Étape 3 : développement de la norme. On développe $\|y - Ax_0\|^2$:

$$\|y - Ax_0\|^2 = y^T y - 2y^T A x_0 + x_0^T A^T A x_0 \tag{78}$$

En prenant l'espérance sous $q(x_0) = \prod_{i=1}^n q_i(x_{0,i})$:

$$\begin{aligned}\left\langle \|y - Ax_0\|^2 \right\rangle_{q(x_0)} &= \|y\|^2 - 2y^T A\langle x_0\rangle + \left\langle x_0^T A^T A x_0 \right\rangle \\ &= \|y\|^2 - 2y^T A\boldsymbol{\mu} + \left\langle \sum_{i,j} (A^T A)_{ij}\, x_{0,i}\, x_{0,j} \right\rangle \end{aligned} \tag{79}$$

où $\boldsymbol{\mu} = \langle x_0\rangle = (\mu_1, \dots, \mu_n)^T$ avec $\mu_i = \langle x_{0,i}\rangle_{q_i}$.

Par séparabilité de $q(x_0)$:

$$\langle x_{0,i}\, x_{0,j}\rangle = \begin{cases} \langle x_{0,i}\rangle\langle x_{0,j}\rangle = \mu_i\mu_j & \text{si } i \neq j \\ \langle x_{0,i}^2\rangle = \mu_i^2 + \Sigma_i & \text{si } i = j \end{cases} \tag{80}$$

où $\Sigma_i = \mathrm{Var}_{q_i}(x_{0,i})$ est la variance marginale.

Donc :

$$\begin{aligned}\left\langle x_0^T A^T A x_0 \right\rangle &= \boldsymbol{\mu}^T A^T A\boldsymbol{\mu} + \sum_{i=1}^n (A^T A)_{ii}\, \Sigma_i \\ &= \boldsymbol{\mu}^T A^T A\boldsymbol{\mu} + \mathrm{tr}\big(\mathrm{diag}(A^T A)\cdot \boldsymbol{\Sigma}\big) \end{aligned} \tag{81}$$

où $\mathrm{diag}(M)$ désigne le vecteur des éléments diagonaux de M et $\boldsymbol{\Sigma} = (\Sigma_1, \dots, \Sigma_n)^T$.

En substituant dans (79) :

$$\left\langle \|y - Ax_0\|^2 \right\rangle_{q(x_0)} = \|y - A\boldsymbol{\mu}\|^2 + \sum_{i=1}^n (A^T A)_{ii}\, \Sigma_i \tag{82}$$

Étape 4 : identification de la loi Gamma. L'expression (77) est de la forme :

$$\log q_{\tau_b}^r(\tau_b) = (\tilde{a}_b - 1)\log \tau_b - \tilde{b}_b\, \tau_b + \mathrm{cte}$$

C'est le logarithme d'une densité $\mathrm{Gamma}(\tilde{a}_b, \tilde{b}_b)$. ■

XIII.8.3 Distribution de référence pour τ_r

Proposition XIII.8.2— Distribution de référence $q_{\tau_r}^r$

Sous l'hypothèse de champ moyen (MF), la distribution de référence pour τ_r est :

$$\boxed{q_{\tau_r}^r(\tau_r) = \mathrm{Gamma}(\tau_r \mid \tilde{a}_r, \tilde{b}_r)} \tag{83}$$

avec :

$$\tilde{a}_r = \frac{n}{2} + a_0 \tag{84}$$

$$\tilde{b}_r = b_0 + \frac{1}{2}\left\langle \|x_0 - \hat{x}_0\|^2 \right\rangle_{q(x_0)} = b_0 + \frac{1}{2}\left(\|\boldsymbol{\mu} - \hat{x}_0\|^2 + \mathrm{tr}(\boldsymbol{\Sigma})\right) \tag{85}$$

Démonstration.

Étape 1 : identification des termes pertinents. Dans (73), seuls (T3) et (T4) dépendent de τ_r :

$$\log q^r_{\tau_r}(\tau_r) = \left\langle \frac{n}{2}\log\tau_r - \frac{\tau_r}{2}\|x_0-\hat{x}_0\|^2 + (a_0-1)\log\tau_r - b_0\tau_r \right\rangle_{q(x_0)} + \text{cte} \tag{86}$$

Étape 2 : moyenne sur x_0. On développe :

$$\|x_0-\hat{x}_0\|^2 = \sum_{i=1}^n (x_{0,i}-(\hat{x}_0)_i)^2 \tag{87}$$

Par séparabilité :

$$\begin{aligned}\left\langle (x_{0,i}-(\hat{x}_0)_i)^2\right\rangle_{q_i} &= \left\langle x_{0,i}^2\right\rangle - 2(\hat{x}_0)_i\langle x_{0,i}\rangle + (\hat{x}_0)_i^2 \\ &= \mu_i^2 + \Sigma_i - 2(\hat{x}_0)_i\mu_i + (\hat{x}_0)_i^2 \\ &= (\mu_i-(\hat{x}_0)_i)^2 + \Sigma_i \end{aligned} \tag{88}$$

En sommant sur i :

$$\left\langle \|x_0-\hat{x}_0\|^2\right\rangle_{q(x_0)} = \|\boldsymbol{\mu}-\hat{x}_0\|^2 + \sum_{i=1}^n \Sigma_i = \|\boldsymbol{\mu}-\hat{x}_0\|^2 + \|\boldsymbol{\Sigma}\|_1 \tag{89}$$

Étape 3 : identification. On obtient :

$$\log q^r_{\tau_r}(\tau_r) = \left(\frac{n}{2}+a_0-1\right)\log\tau_r - \left(b_0 + \frac{1}{2}\|\boldsymbol{\mu}-\hat{x}_0\|^2 + \frac{1}{2}\|\boldsymbol{\Sigma}\|_1\right)\tau_r + \text{cte}$$

C'est une Gamma$(\tilde{a}_r, \tilde{b}_r)$. ■

XIII.8.4 Distribution de référence pour $x_{0,i}$

Le calcul de $q^r_i(x_{0,i})$ est plus délicat car il fait intervenir des formes linéaires et quadratiques. Nous utilisons ici les techniques de calculs de Zheng-Rodet [2] qui permet de traiter systématiquement ces termes.

Résultat XIII.8.1— Technique 1 : Zheng-Rodet

Pour tout vecteur $v \in \mathbb{R}^n$:

$$\int x^T v \prod_{j\neq i} q^k_j(x_j)\,\mathrm{d}x_j = x_i\,v_i + C_1 \tag{90}$$

où $C_1 = \sum_{j\neq i}\mu^k_j\,v_j$ est une constante indépendante de x_i.

Démonstration.

On développe le produit scalaire :

$$x^T v = \sum_{j=1}^{n} x_j\, v_j = x_i\, v_i + \sum_{j\neq i} x_j\, v_j$$

En intégrant sur les x_j pour $j \neq i$:

$$\int x^T v \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j = x_i\, v_i + \sum_{j\neq i} v_j \underbrace{\int x_j\, q_j^k(x_j)\,\mathrm{d}x_j}_{=\mu_j^k} = x_i\, v_i + \sum_{j\neq i} \mu_j^k\, v_j$$

■

Résultat XIII.8.2— Technique 2 : Zheng-Rodet

Pour toute matrice symétrique $H \in \mathbb{R}^{n\times n}$:

$$\boxed{\int x^T H x \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j = x_i^2\, H_{ii} + 2x_i\,(H\boldsymbol{\mu}^k)_i - 2x_i\, H_{ii}\,\mu_i^k + C_2} \tag{91}$$

où C_2 est une constante indépendante de x_i et $\boldsymbol{\mu}^k = (\mu_1^k, \ldots, \mu_n^k)^T$.

Démonstration.

Étape 1 : développement de la forme quadratique.

$$x^T H x = \sum_{p=1}^{n}\sum_{l=1}^{n} H_{pl}\, x_p\, x_l$$

Étape 2 : intégration sur les x_j pour $j \neq i$. On sépare les termes selon qu'ils dépendent de x_i ou non :

$$\int x^T H x \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j = \int \left[x_i^2 H_{ii} + 2x_i \sum_{p\neq i} H_{ip} x_p + \sum_{\substack{p,l\\ p\neq i, l\neq i}} H_{pl} x_p x_l \right] \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j \tag{92}$$

Étape 3 : évaluation terme par terme.

Premier terme : $x_i^2 H_{ii}$ ne dépend pas des x_j pour $j \neq i$, donc :

$$\int x_i^2 H_{ii} \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j = x_i^2 H_{ii}$$

Deuxième terme : Par séparabilité de q^k :

$$\int 2x_i \sum_{p\neq i} H_{ip} x_p \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j = 2x_i \sum_{p\neq i} H_{ip}\mu_p^k$$

Troisième terme : Il ne dépend pas de x_i, donc c'est une constante C_2'.

Étape 4 : réécriture. On a :

$$\sum_{p\neq i} H_{ip}\mu_p^k = \sum_{p=1}^{n} H_{ip}\mu_p^k - H_{ii}\mu_i^k = (H\boldsymbol{\mu}^k)_i - H_{ii}\mu_i^k$$

D'où :

$$\int x^T H x \prod_{j\neq i} q_j^k(x_j)\,\mathrm{d}x_j = x_i^2 H_{ii} + 2x_i\left[(H\boldsymbol{\mu}^k)_i - H_{ii}\mu_i^k\right] + C_2$$

Ce qui donne bien (91). ■

Nous pouvons maintenant calculer $q_i^r(x_{0,i})$.

Proposition XIII.8.3— Distribution de référence q_i^r pour le pixel $x_{0,i}$

Sous l'hypothèse de champ moyen (MF), la distribution de référence pour $x_{0,i}$ est :

$$\boxed{q_i^r(x_{0,i}) = \mathcal{N}(x_{0,i} \mid \mu_i^r, \Sigma_i^r)} \tag{93}$$

avec :

$$(\Sigma_i^r)^{-1} = \frac{\bar{\alpha}_t}{1-\bar{\alpha}_t} + \langle\tau_b\rangle (A^TA)_{ii} + \langle\tau_r\rangle \tag{94}$$

$$\mu_i^r = \Sigma_i^r\left(\frac{\sqrt{\bar{\alpha}_t}}{1-\bar{\alpha}_t}(x_t)_i + \langle\tau_b\rangle\left[(A^Ty)_i - (A^TA)_{ii}\mu_i^k + (A^TA\boldsymbol{\mu}^k)_i\right] + \langle\tau_r\rangle(\hat{x}_0)_i\right) \tag{95}$$

ou, de manière équivalente :

$$\mu_i^r = \Sigma_i^r\left(\frac{\sqrt{\bar{\alpha}_t}}{1-\bar{\alpha}_t}(x_t)_i + \langle\tau_b\rangle\left[(A^Ty)_i - (A^TA\boldsymbol{\mu}_{-i}^k)_i\right] + \langle\tau_r\rangle(\hat{x}_0)_i\right) \tag{96}$$

où $\boldsymbol{\mu}_{-i}^k$ est le vecteur $\boldsymbol{\mu}^k$ avec la i-ème composante mise à zéro.

Démonstration.

Étape 1 : identification des termes pertinents. Dans (73), les termes (T4) et (T5) ne dépendent pas de x_0. On a :

$$\begin{aligned}\log q_i^r(x_{0,i}) &= \langle \log p_t(\boldsymbol{w},\boldsymbol{y})\rangle_{q(\tau_r)\,q(\tau_b)\,\prod_{j\neq i} q_j(x_{0,j})} + \text{cte}\\ &= \left\langle -\frac{\|x_t - \sqrt{\bar{\alpha}_t}\,x_0\|^2}{2(1-\bar{\alpha}_t)} - \frac{\tau_b}{2}\|y - Ax_0\|^2 - \frac{\tau_r}{2}\|x_0 - \hat{x}_0\|^2\right\rangle + \text{cte}\end{aligned} \tag{97}$$

Développons chaque terme en utilisant les théorèmes de Zheng-Rodet XIII.8.1 et XIII.8.2.

Étape 2 : terme forward (T1).

$$\|x_t - \sqrt{\bar{\alpha}_t}\,x_0\|^2 = \|x_t\|^2 - 2\sqrt{\bar{\alpha}_t}\,x_t^Tx_0 + \bar{\alpha}_t\,x_0^Tx_0$$

— Le terme $\|x_t\|^2$ est constant.
— Pour $-2\sqrt{\bar{\alpha}_t}\, x_t^T x_0$, on applique la Proposition XIII.8.1 avec $v = -2\sqrt{\bar{\alpha}_t}\, x_t$:

$$\int -2\sqrt{\bar{\alpha}_t}\, x_t^T x_0 \prod_{j\neq i} q_j^k \,\mathrm{d}x_j = -2\sqrt{\bar{\alpha}_t}\,(x_t)_i\, x_{0,i} + C$$

— Pour $\bar{\alpha}_t\, x_0^T x_0 = \bar{\alpha}_t\, x_0^T I_n x_0$, on applique la Proposition XIII.8.2 avec $H = I_n$:

$$\int \bar{\alpha}_t\, x_0^T x_0 \prod_{j\neq i} q_j^k \,\mathrm{d}x_j = \bar{\alpha}_t\, x_{0,i}^2 + C$$

(car $(I_n)_{ii} = 1$ et les termes linéaires en $x_{0,i}$ s'annulent avec $H = I_n$).

Contribution de (T1) à $\log q_i^r$:

$$-\frac{1}{2(1-\bar{\alpha}_t)}\left(\bar{\alpha}_t\, x_{0,i}^2 - 2\sqrt{\bar{\alpha}_t}\,(x_t)_i\, x_{0,i}\right) + \text{cte} \tag{98}$$

Étape 3 : terme mesure (T2).

$$\|y - Ax_0\|^2 = \|y\|^2 - 2y^T A x_0 + x_0^T A^T A x_0$$

— Le terme $\|y\|^2$ est constant.
— Pour $-2y^T A x_0 = -2(A^T y)^T x_0$, on applique la Proposition XIII.8.1 avec $v = -2A^T y$:

$$\int -2(A^T y)^T x_0 \prod_{j\neq i} q_j^k \,\mathrm{d}x_j = -2(A^T y)_i\, x_{0,i} + C_1 \tag{99}$$

— Pour $x_0^T A^T A x_0$, on applique la Proposition XIII.8.2 avec $H = A^T A$:

$$\int x_0^T A^T A x_0 \prod_{j\neq i} q_j^k \,\mathrm{d}x_j = x_{0,i}^2 (A^T A)_{ii} + 2x_{0,i}\left[(A^T A \boldsymbol{\mu}^k)_i - (A^T A)_{ii}\mu_i^k\right] + C_2 \tag{100}$$

En combinant (99) et (100), la contribution de (T2) à $\log q_i^r$ est :

$$\begin{aligned} &-\frac{\langle \tau_b \rangle}{2}\left[(A^T A)_{ii}\, x_{0,i}^2 + 2x_{0,i}\left[(A^T A \boldsymbol{\mu}^k)_i - (A^T A)_{ii}\mu_i^k\right] - 2(A^T y)_i\, x_{0,i}\right] + \text{cte} \\ &= -\frac{\langle \tau_b \rangle}{2}(A^T A)_{ii}\, x_{0,i}^2 + \langle \tau_b \rangle x_{0,i}\left[(A^T y)_i - (A^T A \boldsymbol{\mu}^k)_i + (A^T A)_{ii}\mu_i^k\right] + \text{cte} \end{aligned} \tag{101}$$

Étape 4 : terme a priori (T3).

$$\|x_0 - \hat{x}_0\|^2 = \|x_0\|^2 - 2\hat{x}_0^T x_0 + \|\hat{x}_0\|^2$$

Par les mêmes arguments (Propositions XIII.8.1 et XIII.8.2 avec $H = I_n$ et $v = -2\hat{x}_0$) :

$$-\frac{\langle \tau_r \rangle}{2}\left(x_{0,i}^2 - 2(\hat{x}_0)_i\, x_{0,i}\right) + \text{cte} \tag{102}$$

Étape 5 : combinaison. En sommant (98), (101) et (102) :

$$\log q_i^r(x_{0,i}) = -\frac{1}{2}\underbrace{\left(\frac{\bar{\alpha}_t}{1-\bar{\alpha}_t} + \langle\tau_b\rangle(A^TA)_{ii} + \langle\tau_r\rangle\right)}_{=:(\Sigma_i^r)^{-1}} x_{0,i}^2$$
$$+ x_{0,i}\left(\frac{\sqrt{\bar{\alpha}_t}}{1-\bar{\alpha}_t}(x_t)_i + \langle\tau_b\rangle \underbrace{\left[(A^Ty)_i - (A^TA\boldsymbol{\mu}^k)_i + (A^TA)_{ii}\mu_i^k\right]}_{\text{terme mesure}} + \langle\tau_r\rangle(\hat{x}_0)_i\right)$$
$$+ \text{cte} \tag{103}$$

Étape 6 : identification. C'est le log d'une gaussienne $\mathcal{N}(\mu_i^r, \Sigma_i^r)$:

$$\log \mathcal{N}(x \mid \mu, \sigma^2) = -\frac{x^2}{2\sigma^2} + \frac{\mu}{\sigma^2}x + \text{cte}$$

Par identification :

$$(\Sigma_i^r)^{-1} = \frac{\bar{\alpha}_t}{1-\bar{\alpha}_t} + \langle\tau_b\rangle(A^TA)_{ii} + \langle\tau_r\rangle$$
$$\frac{\mu_i^r}{\Sigma_i^r} = \frac{\sqrt{\bar{\alpha}_t}}{1-\bar{\alpha}_t}(x_t)_i + \langle\tau_b\rangle\left[(A^Ty)_i - (A^TA\boldsymbol{\mu}^k)_i + (A^TA)_{ii}\mu_i^k\right] + \langle\tau_r\rangle(\hat{x}_0)_i$$

En multipliant par Σ_i^r, on obtient (95).

Étape 7 : forme alternative. On peut réécrire le terme entre crochets :

$$\begin{aligned}(A^Ty)_i - (A^TA\boldsymbol{\mu}^k)_i + (A^TA)_{ii}\mu_i^k &= (A^Ty)_i - \sum_{j=1}^n (A^TA)_{ij}\mu_j^k + (A^TA)_{ii}\mu_i^k \\ &= (A^Ty)_i - \sum_{j\neq i}(A^TA)_{ij}\mu_j^k \\ &= (A^Ty)_i - (A^TA\boldsymbol{\mu}_{-i}^k)_i \end{aligned} \tag{104}$$

où $(\boldsymbol{\mu}_{-i}^k)_j = \mu_j^k$ si $j \neq i$ et $(\boldsymbol{\mu}_{-i}^k)_i = 0$. D'où (96). ■

XIII.8.5 Mise à jour EMG-VBA

Proposition XIII.8.4— Mise à jour de $q_i(x_{0,i})$

Soit $q_i^k(x_{0,i}) = \mathcal{N}(x_{0,i} \mid \mu_i^k, \Sigma_i^k)$. La mise à jour EMG-VBA donne :

$$\boxed{q_i^{k+1}(x_{0,i}) = \mathcal{N}(x_{0,i} \mid \mu_i^{k+1}, \Sigma_i^{k+1})} \tag{105}$$

avec :

$$\Sigma_i^{k+1} = \left(\frac{1 - s_1 + s_2}{\Sigma_i^k} + \frac{s_1}{\Sigma_i^{r,k}} - \frac{s_2}{\Sigma_i^{k-1}}\right)^{-1} \tag{106}$$

$$\mu_i^{k+1} = \Sigma_i^{k+1}\left(\frac{(1 - s_1 + s_2)\mu_i^k}{\Sigma_i^k} + \frac{s_1\mu_i^{r,k}}{\Sigma_i^{r,k}} - \frac{s_2\mu_i^{k-1}}{\Sigma_i^{k-1}}\right) \tag{107}$$

où $\mu_i^{r,k}$ et $\Sigma_i^{r,k}$ sont calculés par (94)–(95) avec les paramètres à l'itération k.

Démonstration.

Étape 1 : forme de la mise à jour. Par (68) :

$$q_i^{k+1}(x_{0,i}) \propto q_i^k(x_{0,i})^{1-s_1+s_2} \cdot q_i^{r,k}(x_{0,i})^{s_1} \cdot q_i^{k-1}(x_{0,i})^{-s_2} \tag{108}$$

Étape 2 : produit de densités gaussiennes. Pour une gaussienne $\mathcal{N}(\mu, \sigma^2)$:

$$\log \mathcal{N}(x \mid \mu, \sigma^2) = -\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x + \text{cte}$$

En prenant le log :

$$\begin{aligned}\log q_i^{k+1}(x_{0,i}) = (1 - s_1 + s_2)&\left[-\frac{x_{0,i}^2}{2\Sigma_i^k} + \frac{\mu_i^k}{\Sigma_i^k}x_{0,i}\right] \\ &+ s_1\left[-\frac{x_{0,i}^2}{2\Sigma_i^{r,k}} + \frac{\mu_i^{r,k}}{\Sigma_i^{r,k}}x_{0,i}\right] \\ &- s_2\left[-\frac{x_{0,i}^2}{2\Sigma_i^{k-1}} + \frac{\mu_i^{k-1}}{\Sigma_i^{k-1}}x_{0,i}\right] + \text{cte}\end{aligned} \tag{109}$$

Étape 3 : regroupement. En regroupant :

$$\begin{aligned}\log q_i^{k+1}(x_{0,i}) = -\frac{x_{0,i}^2}{2}&\underbrace{\left[\frac{1 - s_1 + s_2}{\Sigma_i^k} + \frac{s_1}{\Sigma_i^{r,k}} - \frac{s_2}{\Sigma_i^{k-1}}\right]}_{=1/\Sigma_i^{k+1}} \\ &+ x_{0,i}\underbrace{\left[\frac{(1 - s_1 + s_2)\mu_i^k}{\Sigma_i^k} + \frac{s_1\mu_i^{r,k}}{\Sigma_i^{r,k}} - \frac{s_2\mu_i^{k-1}}{\Sigma_i^{k-1}}\right]}_{=\mu_i^{k+1}/\Sigma_i^{k+1}} + \text{cte}\end{aligned} \tag{110}$$

Étape 4 : identification. Par identification avec $\log \mathcal{N}$, on obtient les formules annoncées. ■

Références

[1] G. Daras, H. Chung, C.-H. Lai, Y. Mitsufuji, J. C. Ye, P. Milanfar, A. G. Dimakis, and M. Delbracio.
A survey on diffusion models for inverse problems.
arXiv preprint arXiv :2410.00083, 2024.

[2] Y. Zheng, A. Fraysse and T. Rodet.
Efficient Variational Bayesian Approximation Method Based on Subspace optimization.
In *IEEE Transactions on Image Processing*, 2014

[3] H. Chung, J. Kim, M. T. McCann, M. L. Klasky, and J. C. Ye.
Diffusion posterior sampling for general noisy inverse problems.
In *International Conference on Learning Representations (ICLR)*, 2023.

[4] J. Song, A. Vahdat, M. Mardani, and J. Kautz.
Pseudoinverse-guided diffusion models for inverse problems.
In *International Conference on Learning Representations (ICLR)*, 2023.

[5] B. D. O. Anderson.
Reverse-time diffusion equation models.
Stochastic Processes and their Applications, 12(3) :313–326, 1982.

[6] P. Vincent.
A connection between score matching and denoising autoencoders.
Neural Computation, 23(7) :1661–1674, 2011.